# Verbeteren van transparantie en herleidbaarheid en begrijpbaarheid van impactanalyses bij VLAIO met OpenMetadata.

**Yu-lan Heremans.**

Scriptie voorgedragen tot het bekomen van de graad van
Professionele bachelor in de toegepaste informatica

**Promotor:** Dhr. S. Lievens
**Co-promotor:** Dhr. K. Coenye
**Instelling:** VLAIO
**Academiejaar:** 2025–2026
**Eerste examenperiode**

**Departement IT en Digitale Innovatie .**

HO GENT

# Woord vooraf

TODO

# Samenvatting

TODO

# Inhoudsopgave


**Lijst van figuren** viii

**Lijst van tabellen** ix

**Lijst van codefragmenten** x

**1 Inleiding** 1
- 1.1 Probleemstelling . . . 1
- 1.2 Onderzoeksvraag . . . 2
- 1.3 Onderzoeksdoelstelling . . . 3
- 1.4 Opzet van deze bachelorproef . . . 3

**2 Stand van zaken** 5
- 2.1 Data lineage en provenance . . . 5
- 2.2 Data lineage binnen data governance . . . 7
- 2.3 Data lineage en impactanalyse . . . 8
- 2.4 Meetbaarheid van data governance en procesverbetering . . . 10
- 2.5 Metadata management tools en data catalogs . . . 10
- 2.6 Positionering van OpenMetadata . . . 11
- 2.7 Onderzoeksleemte . . . 12

**3 Methodologie** 13
- 3.1 Methodologie . . . 13
  - 3.1.1 Fase 1: Analyse van de praktijkcontext en afbakening van de cases . . . 14
  - 3.1.2 Fase 2: Ontwerp en implementatie van de proof-of-concept . . . 14
  - 3.1.3 Fase 3: Evaluatie en interpretatie van de proof-of-concept . . . 15

**4 Analyse van de context** 17
- 4.1 Datalakehouse en medallion-architectuur bij VLAIO . . . 17
- 4.2 Basis-lineage in Databricks en Unity Catalog . . . 18
- 4.3 Impactanalyses bij VLAIO: definitie, triggers en rol van dataherkomst . . . 19
- 4.4 Huidige pijnpunten in het impactanalyseproces . . . 20
- 4.5 Huidige basis-lineage met OpenMetadata en lacunes richting Power BI . . . 20

**5 Proof-of-concept implementatie met OpenMetadata 23**
5.1 Doel en positionering van de proof-of-concept . . . 23
5.2 Technische omgeving en architectuur . . . 24
5.3 Datasets en metadata-bronnen . . . 25
5.4 Mapping van Power BI-datasets naar platinum-datasets . . . 27
5.4.1 Algemene mappingstrategie . . . 27
5.4.2 Heuristieken en outputstructuur . . . 28
5.5 Dashboards en lineage in OpenMetadata . . . 31
5.5.1 End-to-end-flow voor Steunster . . . 31
5.5.2 Belangrijkste notebook-code . . . 32
5.5.3 Lineage voor composite-modellen . . . 37
5.6 Beheer en opschoning van testartefacten . . . 38
5.7 Beperkingen en randvoorwaarden . . . 38
5.7.1 Beperkingen van de naamgebaseerde mapping . . . 39
5.7.2 Rol en onderhoud van de YAML-mappings . . . 39
5.7.3 Beperkingen van lineage op kolomniveau . . . 39
5.7.4 Scope van de implementatie . . . 40

**6 Evaluatie proof-of-concept 41**
6.1 Doel en onderzoeksvragen . . . 41
6.2 Onderzoeksopzet . . . 42
6.2.1 Vragenlijst “Begrijpbaarheid en vertrouwen in rapporten” . . . 42
6.2.2 Scenario en visualisatie van dataherkomst . . . 43
6.3 Resultaten . . . 43
6.3.1 Profiel van de respondenten . . . 43
6.3.2 Huidige ervaring zonder expliciet inzicht in dataherkomst . . . 43
6.3.3 Ervaren meerwaarde van het lineage-overzicht . . . 45
6.3.4 Impact op vertrouwen en gebruik . . . 46
6.3.5 Verschillen tussen gebruikersprofielen . . . 46
6.3.6 Synthese en kritische interpretatie . . . 47

**7 Conclusie 48**

**A Onderzoeksvoorstel 49**
A.1 Inleiding . . . 50
A.1.1 Onderzoeksopzet . . . 50
A.1.2 Probleemstelling . . . 50
A.1.3 Onderzoeksvraag . . . 50
A.1.4 Onderzoeksdoelstelling . . . 51
A.2 Literatuurstudie . . . 51
A.2.1 De rol van data lineage in data governance . . . 51
A.2.2 Compliance en transparantie . . . 52
A.2.3 Impactanalyses . . . 52

A.2.4 OpenMetadata als governance tool . . . . . 53
A.2.5 Praktijkervaringen met OpenMetadata . . . . . 53
A.2.6 Best practices . . . . . 53
A.2.7 Onderzoeksleemte . . . . . 54
A.3 Methodologie . . . . . 54
A.3.1 Voorbereidende fase: Literatuurstudie . . . . . 54
A.3.2 Fase 1: Analyse huidige situatie en nulmeting (3 weken) . . . . . 54
A.3.3 Fase 2: Ontwerp en implementatie proof-of-concept (4 weken) . 55
A.3.4 Fase 3: Nameting en evaluatie (2 weken) . . . . . 56
A.3.5 Fase 4: Analyse, rapportage en aanbevelingen (3 weken) . . . . . 56
A.3.6 Tools en technologieën . . . . . 57
A.4 Verwacht resultaat, conclusie . . . . . 57

**Bibliografie** **59**

# Lijst van figuren

# Lijst van tabellen

5.1 Verkort fragment uit `PowerBI_to_Platinum_mapping_confirmed.csv`. 29

# Lijst van codefragmenten

5.1 Query om Power BI-rapporten en -datasets te selecteren uit Databricks 27
5.2 Fragment uit PowerBI_Dataset_Mappings.yml . . . . . 30
5.3 Fragment uit Platinum_Dataset_Mappings.yml . . . . . 30
5.4 OpenMetadata clientconnectie . . . . . 32
5.5 PBI-data en mappings inladen en verwerken . . . . . 33
5.6 Functies voor het opzoeken van de brontabel . . . . . 33
5.7 Opzoeken bestaande dashboards . . . . . 34
5.8 Dashboards maken en posten naar OpenMetadata . . . . . 35
5.9 Lineage aanleggen in OpenMetadata . . . . . 36

# 1

# Inleiding

In moderne organisaties worden beslissingen steeds vaker genomen op basis van grote hoeveelheden data die uit uiteenlopende bronnen en pipelines samenkomen. Binnen zulke complexe dataomgevingen is het essentieel om te begrijpen waar gegevens vandaan komen, welke transformaties ze doorlopen en hoe ze uiteindelijk in rapporten terechtkomen. Een gebrek aan transparantie over deze dataflow bemoeilijkt niet alleen het uitvoeren van betrouwbare impactanalyses bij wijzigingen, maar tast ook het vertrouwen in datagedreven besluitvorming aan. In deze bachelorproef wordt dit probleem onderzocht in de context van het Vlaams Agentschap Innoveren en Ondernemen (VLAIO), waar een Databricks-lakehouse en Power BI intensief worden gebruikt voor rapportering en impactanalyses rond steunmaatregelen en ondernemerschap.

## 1.1. Probleemstelling

Bij VLAIO worden impactanalyses opgesteld op basis van data die afkomstig is uit verschillende operationele systemen, databronnen en verwerkingspijplijnen. Ondanks deze rijke dataomgeving is er vandaag geen volledig transparant en geïntegreerd lineage-systeem beschikbaar waarmee data-engineers, analisten en rapportbouwers eenvoudig kunnen nagaan welke stappen gegevens doorlopen tussen bron en rapport. De bestaande tooling biedt wel een beperkte vorm van technische lineage binnen Databricks en Unity Catalog, maar deze dekt de volledige keten tot en met Power BI-rapporten niet af en is onvoldoende toegankelijk voor een brede groep gebruikers.

Daardoor is het voor betrokken stakeholders vaak onduidelijk welke databronnen aan de basis liggen van een bepaald cijfer, welke transformaties of business rules zijn toegepast en welke rapporten of dashboards geraakt worden door een wijzi-

ging. Dit leidt tot trage en arbeidsintensieve impactanalyses, een verhoogd risico op fouten in rapportering en een verminderde verklaarbaarheid van de resultaten naar beleidsmakers toe. Bovendien bemoeilijkt het ontbreken van een herbruikbaar, visueel overzicht van dataherkomst en afhankelijkheden het correct interpreteren van wijzigingen in rapporten en het inschatten van hun impact.

De doelgroep van dit onderzoek bestaat in eerste instantie uit de rapportgebruikers, rapportbouwers en technische dataprofielen (zoals data-engineers en BI-ontwikkelaars) binnen VLAIO die betrokken zijn bij het opstellen, onderhouden en interpreteren van rapporten en impactanalyses. Daarnaast ervaren ook beleidsmedewerkers en andere besluitvormers indirect voordelen bij meer transparantie in dataherkomst en afhankelijkheden, omdat dit de betrouwbaarheid, reproduceerbaarheid en begrijpbaarheid van de analyses waarop zij steunen verhoogt.

## 1.2. Onderzoeksvraag

Om de geschetste problemen aan te pakken zet VLAIO in op een metadataplatform met geïntegreerde data lineage. In deze bachelorproef staat de volgende centrale onderzoeksvraag centraal:

> **In welke mate verhogen de lineage-functionaliteit en API-integraties van OpenMetadata de transparantie, herleidbaarheid en ervaren begrijpbaarheid van impactanalyses en rapporten bij VLAIO?**

Om deze vraag concreet te kunnen beantwoorden, wordt ze opgesplitst in een aantal deelvragen.

**Deelvragen probleemdomein:**

1. Wat is data lineage, welke rol speelt het in data governance en compliance, en welke risico's ontstaan wanneer lineage ontbreekt in complexe dataomgevingen?
2. In welke mate zijn impactanalyses en rapporten bij VLAIO momenteel transparant en herleidbaar, en hoeveel tijd en moeite kost het om wijzigingen of fouten te analyseren?

**Deelvragen oplossingsdomein:**

3. Wat zijn de kernfunctionaliteiten van data-catalogus- en metadata-managementtools zoals OpenMetadata voor het beheren van data lineage via API-integraties en connectors?
4. Hoe volledig en nauwkeurig kan de lineage in OpenMetadata worden weergegeven voor representatieve impactanalyse-cases bij VLAIO?

5. Welke praktische barrières en aanbevelingen komen naar voren voor een eventuele verdere implementatie van OpenMetadata binnen VLAIO?
6. Hoe wordt de meerwaarde van OpenMetadata-lineage ervaren door betrokken data-engineers, analisten en rapportgebruikers bij het begrijpen van rapporten en het duiden van wijzigingen?

De eerste en derde deelvraag worden hoofdzakelijk beantwoord op basis van literatuuronderzoek en documentanalyse. De tweede vraag wordt beantwoord in Hoofdstuk 4. Vraag vier en vijf worden beantwoord in Hoofdstuk 5. En ten slotte wordt vraag zes beantwoord in Hoofdstuk 6.

## 1.3. Onderzoeksdoelstelling

Het doel van deze bachelorproef is om via een praktijkgerichte case study de meerwaarde van OpenMetadata-lineage voor impactanalyses en rapportgebruik bij VLAIO systematisch in kaart te brengen. Concreet wordt een proof-of-concept opgezet waarin Power BI-rapporten en onderliggende Databricks-platinumdatasets aan elkaar gekoppeld worden via OpenMetadata, waarna de opgebouwde lineage wordt geëvalueerd op bruikbaarheid, duidelijkheid en ervaren meerwaarde door de betrokken stakeholders zelf.
De evaluatie gebeurt via een gestructureerde online vragenlijst, aangevuld met kwalitatieve analyse van de antwoorden en de observaties uit interne afstemmomenten. De beoogde resultaten zijn enerzijds een onderbouwd inzicht in hoe OpenMetadata de transparantie, herleidbaarheid en begrijpbaarheid van impactanalyses kan ondersteunen, en anderzijds concrete aanbevelingen over hoe data-engineers en analisten lineage structureel kunnen integreren in hun werkwijze binnen de VLAIO-context.

## 1.4. Opzet van deze bachelorproef

De rest van deze bachelorproef is als volgt opgebouwd:

In Hoofdstuk 2 wordt een overzicht gegeven van de stand van zaken binnen het onderzoeksdomein, op basis van een literatuurstudie.

In Hoofdstuk 3 wordt de methodologie toegelicht en worden de gebruikte onderzoekstechnieken besproken om een antwoord te kunnen formuleren op de onderzoeksvragen.

In Hoofdstuk 4 wordt de praktijkcontext bij VLAIO geanalyseerd, met bijzondere aandacht voor de Databricks-architectuur, het huidige impactanalyseproces en de bestaande mogelijkheden en lacunes rond lineage.

In Hoofdstuk 5 wordt de proof-of-concept in OpenMetadata ontworpen, geïmplementeerd en technisch gedocumenteerd.

In Hoofdstuk 6 wordt de meerwaarde van de proof-of-concept geëvalueerd aan de hand van de vragenlijst *"Begrijpbaarheid en vertrouwen in rapporten"* en een kwalitatieve interpretatie van de resultaten.

In Hoofdstuk 7, tenslotte, wordt de conclusie geformuleerd en een antwoord gegeven op de onderzoeksvragen. Daarbij wordt ook een aanzet gegeven voor toekomstig onderzoek en verdere implementatiestappen binnen dit domein.

# 2

# Stand van zaken

In dit hoofdstuk wordt de theoretische en contextuele achtergrond gepresenteerd die nodig is voor het bestuderen van transparantie en herleidbaarheid van impactanalyses bij VLAIO. Eerst worden de begrippen data lineage en provenance toegelicht, gevolgd door de rol van lineage binnen data governance en impactanalyse. Daarna wordt besproken hoe de meerwaarde van lineage in een organisatiecontext kan worden geëvalueerd. Vervolgens komen metadata management, data catalogs en de positionering van OpenMetadata aan bod. Tot slot wordt de onderzoeksleemte afgebakend. Dit hoofdstuk vormt het referentiekader voor de interpretatie van de case study en de evaluaties die in de volgende hoofdstukken aan bod komen.

## 2.1. Data lineage en provenance

Bij VLAIO verwijst Data lineage naar de volledige weg die data binnen een organisatie aflegt van de initiële bron tot het eindrapport of een andere analytische toepassing. Het beschrijft zowel de herkomst van gegevens, maar kan ook alle transformaties, uitbreidingen en afhankelijkheden van de data, doorheen verschillende systemen zichtbaar maken. Zoals Verma et al. (2024) beschreven, bewegen datasets met verschillende stappen door een data-pipeline, waarbij deze continu van vorm veranderen. Data lineage documenteert deze opeenvolgende stappen en geeft inzicht in hoe de data wordt verzameld, verwerkt en uiteindelijk gebruikt binnen de organisatie.

In de literatuur wordt naast de term data lineage ook de term data provenance gebruikt. Hoewel ze vaak door elkaar gebruikt worden (Mayernik et al., 2013), hebben ze elk een specifiek doel (infobelPRO, 2025). Lineage richt zich op de geschie-

denis van de data en dependency graphs tussen data-resources (Mayernik et al., 2013), oftewel de documentatie hoe data verwerkt wordt en beweegt door systemen (Patel et al., 2020). Provenance focust daarentegen op de oorspong of bron van verwerkingsresultaten, de historische en contextuele achtergrond met informatie over systemen en processen (Mayernik et al., 2013; Patel et al., 2020). In de praktijk worden beide idealiter gecombineerd. Op die manier ontstaat er een breder beeld van betrouwbaarheid, waarbij data lineage inzicht geeft in de dataflow en data provenance de oorsprong en authenticiteit van de data bewijst (infobel-PRO, 2025).

Binnen data-intensieve omgevingen worden lineage en provenance gezien als een cruciale component voor het garanderen van transparantie, herleidbaarheid en herbruikbaarheid van data (Mayernik et al., 2013). Ze zorgen voor vertrouwen in de data, voorkomt misinterpretatie door gebruikers door de verwerkingsstappen van de data duidelijk te communiceren en helpt bij het beoordelen van data-kwaliteit en geschiktheid voor specifieke toepassingen (Mayernik et al., 2013). Ook het traceren van fouten wordt efficiënter. Dit is zeer relevant in complexe en gedistribueerde data-architecturen met meerdere databronnen, transformatielagen en systemen zoals bijvoorbeeld een cloudomgeving (Patel et al., 2020).

Een gebrek aan een goed gestructureerde lineage of provenance kan leiden tot een verminderde transparantie bij de totstandkoming van bepaalde resultaten. Wanneer afhankelijkheden onvoldoende gedocumenteerd zijn, wordt het moeilijker om foutdetecties of impactanalyses uit te voeren, wanneer datasets of processen gewijzigd worden (Patel et al., 2020). Hierdoor neemt dus de controleerbaarheid van rapportages en impactanalyses af, wat potentieel negatieve gevolgen heeft voor de besluitvorming binnen een organisatie (Verma et al., 2024). Patel et al. (2020) benadrukken bovendien dat onvolledige herleidbaarheid in gedistribueerde of cloud-omgevingen het identificeren van fouten aanzienlijk kan vertragen.

Een goede lineage-implementatie is volgens Tang et al. (2022) niet zonder uitdagingen. Bestaande studies tonen aan dat implementaties vaak geen volledige SQL of procedurele talen ondersteunen, met als gevolg dat complexe SQL-queries en procedurele structuren dus moeilijk te traceren zijn. Daarnaast kan een gebrek aan multi-granulariteit op tuple/value-niveau en een beperkte ondersteuning voor complexe transformatieprocessen leiden tot een onvolledige afhankelijkheidsdetectie. Een effectieve toepassing vereist daarom robuuste modellen voor SQL-syntax en datatransformaties, naast governance voor consistente metadata.

## 2.2. Data lineage binnen data governance

Data governance omvat alle principes en frameworks die het beheer van data structureren, met de nadruk op de beveiliging, regelgeving, processen, rollen en verantwoordelijkheden om data binnen een organisatie te beheren en strategisch te kunnen gebruiken (Verma et al., 2024). Verma et al. (2024) stellen dat een organisatie goede governance nodig heeft voor vlotte en duurzame operaties, met de focus op data-kwaliteit, veiligheid en compliance. Door het voorzien van gestandaardiseerde data, definities en validatie regels, zorgt governance voor een groter vertrouwen in de data binnen een organisatie.

Echter is het implementeren van governance geen eenvoudige taak en vereist meerdere stappen en pre-condities, zoals onder andere managementondersteuning ()executive support), duidelijke bedrijfsdoelstellingen en een volledige inventarisatie van de data (Verma et al., 2024). Hoewel governance het vertrouwen in data via standaarden, definities en validatieregels wil verhogen, blijft dit moeilijk als er geen transparantie is in de oorsprong en de bewerkingen van de data. Dit is waar data lineage te pas komt. Het maakt zichtbaar waar de data vandaan komt, hoe ze wordt getransformeerd en waar ze naartoe gaat. Verma et al. (2024) beschrijven dat data lineage een component van governance is die zorgt voor transparantie, de sleutelvereiste voor effectieve governance. In het kader van deze bachelorproef wordt transparantie niet gezien als publieke openbaarheid van de gegevens, maar als een interne en governancegerichte transparantie binnen VLAIO. Dit betekent dat data engineers, data analisten, auditors en rapportgebruikers inzicht hebben in de oorsprong, transformaties en afhankelijkheden van data assets. Deze vorm van transparantie ondersteunt de interne controleerbaarheid en verantwoordingsplicht, blijvend binnen de voorwaarden van GDPR, zoals dataminimalisatie[1] en gepaste toegangscontrole. Daarnaast zorgt deze herleidbaarheid ook voor governance doelen zoals verantwoordingsplicht (accountability), kwaliteitsgarantie, informatiebeveiliging en impactanalyse (Verma et al., 2024).

Naast deze governance doelen, speelt lineage ook een belangrijke rol als ondersteuning binnen regelgevings- en privacycontexten zoals GDPR (General Data Protection Regulation) of andere compliancevereisten. Malviya et al. (2025) tonen aan dat een transparante data lineage controleerbaarheid (auditability) sterk verhoogt. Zo worden DSAR-verzoeken[2] 64% sneller afgehandeld en audit-evidence[3] 80% efficiënter samengesteld. Hierdoor kan een organisatie beter demonstreren dat ze

[1] Persoonsgegevens mogen enkel verzameld en verwerkt worden indien deze noodzakelijk zijn voor het specifieke doel, waarvoor ze worden gebruikt.

[2] Verzoeken van betrokkenen in het kader van GDPR, bijvoorbeeld voor inzage, correctie of verwijdering van persoonsgegevens.

[3] Bewijsmateriaal dat aantoont dat processen, controles en gegevensverwerkingen voldoen aan geldende regelgeving en interne governance-eisen

regelgeving als GDPR naleven. Bovendien kan de transparantie ervoor zorgen dat een organisatie een betere relatie kan opbouwen met zijn stakeholders en met meer vertrouwen belangrijke beslissingen nemen (Verma et al., 2024). Deze voordelen zijn zeker interessant, maar niet van toepassing in dit onderzoek.

In deze bachelorproef wordt dieper ingegaan op impactanalyse. Meer specifiek wordt onderzocht hoe data lineage als governance-tool kan bijdragen aan de transparantie, herleidbaarheid en betrouwbaarheid van impactanalyses.

## 2.3. Data lineage en impactanalyse

Change Impact Analysis ofwel impactanalyse wordt door Kretsou et al. (2021) beschreven als het proces dat onderzoekt welke gevolgen een wijziging kan hebben op andere onderdelen binnen een systeem. Binnen een data-intensieve omgeving wil dit concreet zeggen dat wijzigingen binnen datasets, datamodellen of transformatieprocessen systematisch worden geëvalueerd op de downstream-effecten die ze hebben. Binnen de context van databronnen wordt er een onderscheid gemaakt tussen upstream en downstream bronnen. Upstream verwijst naar dataronnen of processen die data leveren aan een bepaald punt in de dataketen en downstream verwijst naar systemen of processen die de data ontvangen of gebruiken. Zonder inzicht in de onderlinge afhankelijkheden tussen databronnen, transformaties en rapportages wordt het echter moeilijk om te bepalen welke onderdelen van een organisatie beïnvloed worden, wanneer een bepaalde wijziging doorgevoerd wordt.

Met lineage duidelijk kan zien welke upstream-bronnen bijdragen aan specifieke datasets en welke downstream rapporten, dashboards of andere processen van deze data afhankelijk zijn. Dit kan zeer interessant zijn bij het uitvoeren van betrouwbare impactanalyses. Data lineage maakt het mogelijk om veranderingen gericht te analyseren en evalueren voordat ze in de praktijk worden doorgevoerd. Zonder dit inzicht wordt het achterhalen van de impact die wijzigingen met zich mee brengen vaak een manueel en tijdrovend proces, aangezien je elke afhankelijkheid per dataset of zelfs per veld moet controleren (Malviya et al., 2025). Wanneer er binnen een organisatie een voorstel wordt gedaan voor een wijziging, als een systeemupgrade of een data transformatie, kan je dus aan de hand van data lineage zien welke downstream processen of data gebruikers er geraakt zullen worden. Dit zorgt vervolgens voor een beter risicobeoordeling en mitigatieplanning, het voorkomen van negatieve gevolgen van een specifiek risico of proces (Verma et al., 2024).

Daarnaast ondersteunen data lineage en provenance de reproduceerbaarheid van resultaten. Dit komt omdat ze traceerbaarheid mogelijk maken. Het documente-

ren van de lineage en de verwerking van de data maakt het mogelijk inputs en outputs van processen te traceren in een gedistribueerde datachain (Wittner et al., z.d.). Dit versterkt niet alleen de betrouwbaarheid van de data bij het uitvoeren van analyses, maar ook de interne, governancegerichte transparantie en herleidbaarheid die nodig zijn om impactanalyses en samenhangende besluitvormingen te ondersteunen (Verma et al., 2024). Transparantie wordt in deze bachelorproef niet gezien als publieke openbaarheid, maar als inzicht voor relevante interne actoren zoals data engineers, analisten, auditers en rapportgebruikers, binnen de geldende AVG-randvoorwaarden van VLAIO.

Het is belangrijk te benadrukken dat de inhoud en context van impactanalyses organisatieafhankelijk zijn. Bij VLAIO is een impactanalyse niet enkel een technische oefening waarbij afhankelijkheden tussen datasets worden opgespoord, maar omvat ook het toelichten van de impact van wijzigingen aan verschillende betrokkenen, het documenteren van beslissingen en het ondersteunen van de verdere uitvoering in rapportering en datapijplijnen. Hoewel impactanalyse in de literatuur vaak wordt benaderd als een technisch proces waarbij de gevolgen van wijzigingen in datasets, transformaties of rapportagesystemen systematisch in kaart worden gebracht, wordt het concept in deze bachelorproef ruimer benaderd binnen een data governance-context. Impactanalyse wordt daarbij niet alleen opgevat als een formele activiteit voor data engineers of ontwikkelaars, maar ook als een proces waarbij andere gebruikers van data, zoals analisten en businessgebruikers, nood hebben aan inzicht in de herkomst, betekenis en betrouwbaarheid van gegevens. Wanneer zij geconfronteerd worden met gewijzigde rapporten, onverwachte waarden of onduidelijke verschillen in output, stellen ook zij in essentie vragen naar de impact van onderliggende wijzigingen. In dat opzicht verschuift de focus van louter technische afhankelijkheidsdetectie naar vragen rond vertrouwen, betekenis en herkomst van data. Data lineage kan hierin een belangrijke rol spelen, doordat het niet alleen formele impactanalyses ondersteunt, maar ook bredere transparantie en herleidbaarheid mogelijk maakt voor een ruimer gebruikerspubliek. De gemeten verbeteringen zijn daarbij niet uitsluitend technisch, maar komen ook voort uit het expliciet maken en centraliseren van impliciete kennis die voordien verspreid aanwezig was. Deze bredere interpretatie sluit aan bij het governance-perspectief van deze bachelorproef, waarin de meerwaarde van lineage niet enkel technisch, maar ook vanuit begrijpelijkheid en bruikbaarheid voor stakeholders wordt benaderd.

## 2.4. Meetbaarheid van data governance en procesverbetering

In de literatuur worden duidelijk de strategische en operationele voordelen van data lineage binnen de context van data governance en impactanalyses naar voor gebracht (Bernardo et al., 2024; Verma et al., 2024). Echter is het aantonen van deze verbeteringen in de praktijk niet altijd vanzelfsprekend. Men gebruikt vaak de termen transparantie en verantwoordingsplicht, maar deze worden niet vaak vertaald naar concrete en meetbare procesincicatoren. Dit maakt het lastig om geclaimde voordelen in de praktijk aan te tonen.

Wanneer de focus ligt op impactanalyse in een concrete organisatiecontext, kan de bijdrage van lineage daarom ook op een praktijkgerichte manier geëvalueerd worden. Naast mogelijke observaties van het analyseproces kan daarbij vooral gekeken worden naar hoe gebruikers de beschikbaarheid en bruikbaarheid van lineage-informatie ervaren: begrijpen zij beter waar data vandaan komt, hebben zij meer vertrouwen in de rapportering en kunnen zij afhankelijkheden duidelijker reconstrueren en communiceren?

Een dergelijke evaluatie is dus zeker relevant omdat de meerwaarde van lineage niet uitsluitend technisch is. Verbeteringen kunnen immers ook voortkomen uit het explicieter documenteren en centraliseren van kennis die voordien verspreid of impliciet aanwezig was in de organisatie. De evaluatie van een lineage-oplossing moet daarom niet alleen aandacht hebben voor technische zichtbaarheid van afhankelijkheden, maar ook voor begrijpelijkheid, bruikbaarheid en ervaren ondersteuning bij impactanalyses.

## 2.5. Metadata management tools en data catalogs

In essentie steunt data lineage op metadata. Metadata is beschrijvende informatie over data zoals onder andere welke data assets er bestaan, semantiek van data, waar deze assets zich bevinden, door welke systemen en transformaties ze bewegen en of deze confidentieel zijn (Eichler et al., 2021). Metadata management is een verzameling van alle activiteiten om data assets via hun metadata te beheren. Zonder metadata weet een organisatie niet welke data ze bezitten, wat die representeert en of ze vertrouwelijk is, waardoor doelstellingen als compliance en het volledig kunnen benutten van datawaarde in bedwang komen (Eichler et al., 2021). Volgens Eichler et al. (2021) is data transparantie het vinden, begrijpen en het kunnen raadplegen van data, wat door metadata management kan gewaarborgd worden.

Een data catalog biedt is de technologische tool voor metadata management. Het werkt als een centraal data inventaris met bijhorende documentatie over de geregistreerde databronnen, business-, technische- en operationele metadata (Eichler et al., 2021). Business metadata omvat bijvoorbeeld een definitie of inhoudelijke beschrijving van "customer purschase", technische metadata kan bijvoorbeeld datatype informatie bevatten en operationele metadata beschrijft bijvoorbeeld de gebruiksgeschiedenis van data. Door al deze metadata te centraliseren en beschikbaar te maken in één interface, ondersteunen data catalogs de begrijpbaarheid en vindbaarheid van data over meerdere systemen heen, zowel voor IT als Business.

De meeste moderne metadata platformen gaan echter verder dan enkel data-inventarisatie. Lineage functionaliteit in tools steunt typisch op technische metadata uit systemen zoals bijvoorbeeld schema's, ETL-workflows en logbestanden om datastromen te reconstrueren en te visualiseren, waardoor upstream- en downstreamafhankelijkheden expliciet in kaart worden gebracht en impactanalyses bij wijzigingen rechtstreeks worden ondersteund (Verma et al., 2024). In complexe en gedistribueerde data architecturen zoals datalakes en ERP structuren is een organisatiebrede aanpak zeker interessant, aangezien het voor een individuele medewerker onhaalbaar wordt om een volledig overzicht van alle data en systemen bij te houden (Eichler et al., 2021). Dergelijke platformen zijn vooral relevant wanneer afhankelijkheden verspreid zitten over verschillende databronnen, transformatielagen en rapporteringstools, waardoor manuele reconstructie van de volledige dataflow moeilijk is en zeer veel tijd inneemt.

Binnen dit oplossingsdomein bestaan er zowel commerciële als open source platformen die data cataloging, governance en lineage functionaliteit combineren (Eichler et al., 2021). In deze bachelorproef dient OpenMetadata als representatief voorbeeld van een open source metadata en governanceplatform met geïntegreerde lineage-functionaliteit.

## 2.6. Positionering van OpenMetadata

OpenMetadata wordt in deze bachelorproef gepositioneerd als een open source metadataplatform dat functies biedt voor zowel data cataloging, data governance en data lineage. Het platform omschrijft zichzelf als een geïntegreerd metadata platform ofwel een plek waar alle metadata van een organisatie overzichtelijk samenkomt. Een centrale plek dus voor data discovery, observability en governance, ondersteund door een metadata repository en lineage (OpenMetadata, 2024d). Binnen VLAIO werd OpenMetadata gekozen als metadata management tool na een evaluatie naast 17 alternatieve tools, waaronder bijvoorbeeld Microsoft Purview. Volgens de betrokken stakeholders voldeed Purview steeds minder aan de noden van

VLAIO, omdat het product evolueerde van een data governance tool naar een meer security en DLP georiënteerde oplossing, met de nadruk op security raporten, tegenover data lineage, definities, ownership en ondersteuning van impactanalyses. OpenMetadata werd dus beoordeeld als beter afgestemd op de governance doelstellingen van VLAIO. Daarnaast is het ook open-source dus is er geen sprake van vendor lock-in, het verschijnsel waarbij een organisatie afhankelijk is aan een bepaalde leverancier en het moeilijk wordt om hiervan af te stappen zonder grote financiële gevolgen.

OpenMetadata past binnen het oplossingsdomein van data catalogs en metadata management omdat de catalogfunctie metadata rond data assets centraal beschikbaar maakt voor vindbaarheid en begrip (Eichler et al., 2021). De lineage functionaliteit maakt bovendien upstream en downstream afhankelijkheden zichtbaar, wat rechtstreeks kan bijdragen aan transparantere en beter onderbouwde impactanalyses bij wijzigingen (OpenMetadata, 2024d; Verma et al., 2024). In deze bachelorproef wordt binnen de context van VLAIO nagegaan in welke mate OpenMetadata kan bijdragen aan transparantere en beter herleidbare impactanalyses.

## 2.7. Onderzoeksleemte

Hoewel literatuur duidelijk aantoont dat data lineage bijdraagt aan transparantie en impactanalyse binnen data governance, blijft het in veel gevallen onduidelijk hoe deze meerwaarde zich manifesteert in een concrete organisatiecontext (Bernardo et al., 2024; Verma et al., 2024) Bestaande studies bespreken lineage vaak op conceptueel of technisch niveau maar besteden minder aandacht aan hoe gebruikers de beschikbaarheid van lineage-informatie ervaren in het kader van impactanalyse, documentatie en rapportering. Daarnaast blijkt uit andere praktijkgevallen dat organisatiebrede metadata management en het samenstellen van een passend toollandschap hiervoor niet evident is, wat de nood aan praktijkgerichte evaluaties versterkt (Eichler et al., 2021). In deze bachelorproef wordt daarom binnen de context van VLAIO onderzocht hoe OpenMetadata de transparantie en herleidbaarheid van impactanalyses en rapporten kan ondersteunen, met bijzondere aandacht voor begrijpelijkheid, bruikbaarheid en ervaren meerwaarde voor betrokken stakeholders.

# 3

# Methodologie

## 3.1. Methodologie

In deze bachelorproef wordt een toegepaste kwalitatieve case study uitgevoerd bij VLAIO naar de meerwaarde van OpenMetadata voor de transparantie en herleidbaarheid van impactanalyses. De nadruk ligt daarbij niet op een strikte voor- en nameting met vaste procesindicatoren, maar op een praktijkgerichte evaluatie van een proof-of-concept (PoC) en de manier waarop deze door betrokken gebruikers ervaren en beoordeeld wordt. Deze keuze sluit aan bij de vaststelling dat impactanalyses binnen VLAIO complex, contextafhankelijk en sterk verweven zijn met bestaande werkafspraken, waardoor een louter kwantitatieve vergelijking op basis van bijvoorbeeld analysetijd of aantallen geraakte rapporten onvoldoende zinvol of moeilijk betrouwbaar uitvoerbaar is.

De methodologie bestaat uit drie fasen: 1) analyse en afbakening van de praktijkcontext, 2) ontwerp en implementatie van een PoC in OpenMetadata, en 3) evaluatie en interpretatie van de PoC op basis van gebruikersfeedback. Deze gefaseerde aanpak laat toe om het onderzoek systematisch op te bouwen, de technische realisatie van lineage te koppelen aan concrete praktijkcases, en de ervaren meerwaarde, beperkingen en aandachtspunten op een onderbouwde manier in kaart te brengen.

Binnen dit onderzoek verwijst transparantie naar interne, governancegerichte transparantie voor data-engineers, analisten, rapportbouwers en andere relevante interne stakeholders. De PoC wordt uitgewerkt binnen de context van VLAIO zoals beschreven in Hoofdstuk 4. Bij de interpretatie van de resultaten wordt er expliciet rekening mee gehouden dat een deel van de ervaren meerwaarde niet uitsluitend voortkomt uit de tool zelf, maar ook uit het explicieter documenteren en centrali-

seren van kennis die voordien verspreid of impliciet aanwezig was.

### 3.1.1. Fase 1: Analyse van de praktijkcontext en afbakening van de cases

Het doel van deze fase is om de huidige werkwijze rond impactanalyses binnen VLAIO beter te begrijpen en om de scope van het praktijkonderzoek af te bakenen. Hiervoor worden bestaande impactanalyse-documenten, relevante rapporteringsketens en de betrokken dataflows verkend. In Hoofdstuk 4 wordt deze analyse samengebracht in een beschrijving van de Databricks-lakehouseomgeving, de medallion-architectuur, de huidige mogelijkheden en beperkingen van lineage, en de manier waarop impactanalyses vandaag verlopen.

In overleg met de co-promotor en andere relevante medewerkers worden één of meerdere representatieve cases geselecteerd die typische impactanalyses weerspiegelen en duidelijk zichtbaar maken waar de huidige zichtbaarheidstekorten in de lineageketen zich situeren. De Steunster/Krissteunster-case wordt daarbij gekozen als centrale demonstratiecase, omdat deze zowel businessmatig belangrijk is als sterk afhankelijk is van de koppeling tussen platinum-datasets en Power BI-rapporten. De geselecteerde cases dienen dus in de eerste plaats om de meerwaarde van betere zichtbaarheid en herleidbaarheid te illustreren, niet om de technische impactanalyseprocessen zelf exhaustief in kaart te brengen.

Daarnaast wordt in deze fase bepaald welke profielen in het empirische luik betrokken worden, met een focus op personen die impactanalyses uitvoeren, ondersteunen of interpreteren, zoals data-engineers, analisten en rapportbouwers. Waar relevant kunnen ook bredere interne stakeholders bevraagd worden over de begrijpbaarheid en het vertrouwen in rapporten, maar niet als hoofdbron voor het beoordelen van het impactanalyseproces zelf.

**Deliverable**: afbakening van de onderzoeksscope, beschrijving van de geselecteerde cases (met de Steunster/Krissteunster-case als kerncase), een overzicht van betrokken profielen en een samenvattende beschrijving van de huidige context van impactanalyse en rapportage.

### 3.1.2. Fase 2: Ontwerp en implementatie van de proof-of-concept

In deze fase wordt een proof-of-concept uitgewerkt in OpenMetadata voor de geselecteerde cases. De PoC richt zich specifiek op het zichtbaar maken van de stap van platinum-datasets in Databricks naar Power BI-datamodellen en -rapporten, aangezien daar in de huidige situatie de grootste zichtbaarheidskloof wordt erva-

ren. OpenMetadata wordt geconfigureerd in functie van de beschikbare metadata over Databricks-tabellen en Power BI-rapporten, en er wordt een generieke naam-gebaseerde mappinglaag gebouwd die Power BI-datasetnamen koppelt aan onderliggende platinum-datasets.

De implementatie maakt gebruik van CSV-exports uit de Power BI REST API en een export van platinum-datasets, die in scripts en notebooks worden ingelezen en verwerkt. De mappinggenerator wordt toegepast op de volledige set Power BI-datasets uit de export en levert voor een aanzienlijk deel daarvan betrouwbare mappings naar platinum-datasets op, terwijl de end-to-end lineage-flow (inclusief dashboardcreatie en het effectief leggen van lineage-edges) in deze PoC volledig wordt doorlopen voor een geselecteerde subset van rapporten, waaronder de Steunster/Krissteunste case als illustratief voorbeeld. De onderliggende scripts en YAML-configuraties zijn echter generiek opgezet, zodat dezelfde aanpak ook voor andere rapporten inzetbaar is.

Naast de technische configuratie wordt ook aandacht besteed aan metadata-verrijking en aan de manier waarop de lineage-informatie bruikbaar gepresenteerd wordt voor de evaluatiefase. De PoC wordt uitgewerkt als een combinatie van herbruikbare Pythonscripts, Jupyter-notebooks en YAML-configuraties, waarbij expliciet wordt gedocumenteerd welke stappen geautomatiseerd zijn en waar manuele tussenkomst nodig is, bijvoorbeeld bij twijfelgevallen in de mapping of bij het opschonen van testdashboards en lineage. De gemaakte ontwerpkeuzes en beperkingen (zoals het focussen op lineage op tabelniveau) worden vastgelegd, zodat de evaluatie in latere hoofdstukken correct binnen deze scope geïnterpreteerd kan worden.

**Deliverable**: een werkende PoC in OpenMetadata die de lineage tussen platinum-datasets en Power BI-rapporten zichtbaar maakt voor de geselecteerde cases, technische documentatie van de configuratie en een logboek met relevante ontwerpkeuzes, beperkingen en technische bevindingen.

### 3.1.3. Fase 3: Evaluatie en interpretatie van de proof-of-concept

In de derde fase wordt de PoC geëvalueerd op haar bruikbaarheid en ervaren meerwaarde voor impactanalyses binnen VLAIO. De kern van deze fase is de online vragenlijst *"Begrijpbaarheid en vertrouwen in rapporten"*, opgesteld in Microsoft Forms en gericht op gebruikers die in meer of mindere mate met rapporten (zoals Power BI) werken. De vragenlijst bevat profielvragen, stellingen over de huidige ervaring zonder extra inzicht in dataherkomst, een scenario met een herkomstoverzicht gebaseerd op de gerealiseerde PoC, bijkomende vragen voor technische rapportbouwers en een algemene evaluatie van de meerwaarde en het verwachte gebruik van

zo'n overzicht. De meeste stellingen worden beantwoord op een vijfpuntsschaal van "helemaal oneens" tot "helemaal eens", aangevuld met open vragen waarin respondenten concrete situaties, barrières of suggesties kunnen beschrijven.

Tijdens de evaluatie wordt een vereenvoudigde visualisatie van de lineageketen getoond, waarin te zien is uit welke databronnen en tussenliggende tabellen een rapport zijn cijfers haalt en welke rapporten geraakt kunnen worden door wijzigingen in de onderliggende datasets. Respondenten wordt gevraagd in welke mate dit soort overzicht hen helpt om cijfers te begrijpen, wijzigingen te verklaren, impact in te schatten en vertrouwen te hebben in de rapporten. Voor technische profielen wordt bovendien nagegaan in welke mate de lineage-overzichten hen ondersteunen bij het plannen en onderbouwen van wijzigingen.

De ingevulde vragenlijsten en eventuele bijkomende toelichtingen worden vervolgens thematisch geanalyseerd. Daarbij wordt gezocht naar terugkerende patronen, zoals ervaren voordelen, knelpunten, ontbrekende informatie of voorwaarden voor breder gebruik van lineage-overzichten. Deze kwalitatieve analyse wordt gekoppeld aan de technische resultaten van de PoC en aan het theoretisch kader uit de literatuurstudie. Op basis hiervan worden conclusies geformuleerd over de centrale onderzoeksvraag en worden aanbevelingen voor VLAIO geformuleerd over het verdere gebruik van OpenMetadata en de rol van lineage in het ondersteunen van impactanalyses.

**Deliverable**: een thematische analyse van de gebruikersfeedback, een onderbouwd antwoord op de onderzoeksvraag en concrete aanbevelingen voor het vervolg, die in de besluitende hoofdstukken verder worden uitgewerkt.

# 4

# Analyse van de context

Dit hoofdstuk beschrijft de organisatorische en technische context waarbinnen impactanalyses bij VLAIO plaatsvinden. Eerst wordt de data-architectuur geschetst, gevolgd door de huidige mogelijkheden en beperkingen van lineage binnen Databricks en Unity Catalog. Vervolgens wordt toegelicht hoe impactanalyses vandaag verlopen en welke rol zicht op dataherkomst en afhankelijkheden daarin speelt. Tot slot wordt beschreven hoe OpenMetadata als mogelijke oplossing wordt ingezet, met specifieke aandacht voor de ontbrekende schakel tussen Databricks en Power BI. Dit hoofdstuk vormt daarmee de brug tussen het theoretisch kader uit de literatuurstudie en de proof-of-concept die in het volgende hoofdstuk wordt uitgewerkt.[1]

## 4.1. Datalakehouse en medallion-architectuur bij VLAIO

De data-omgeving van VLAIO is opgebouwd als een grootschalig data lakehouse op Databricks, waarbij data-opslag, verwerking en analyse samen worden genomen in één platform. In tegenstelling tot klassieke datawarehouses, waar data vaak in sterk gescheiden silo's wordt beheerd, combineert een lakehouse de flexibiliteit van een data lake met de betrouwbaarheid en governance-mogelijkheden van een warehouse. Binnen VLAIO betekent dit concreet dat uiteenlopende bronsystemen hun data aanleveren aan Databricks, waar deze vervolgens via verschillende lagen worden verwerkt tot rapporteerbare datasets.

De architectuur volgt het medallion-patroon met opeenvolgende bronze-, silver- en gold- of platinum-lagen. Hierbij worden in de bronze-laag ruwe extracten uit operationele toepassingen opgeslagen, zonder ingrijpende bewerkingen. In de silver-laag worden deze ruwe gegevens opgeschoond, getransformeerd en gestan-

[1] Dit hoofdstuk is gebaseerd op interne documentatie en afstemmomenten met het CC-Data team.

daardiseerd, bijvoorbeeld door datakwaliteitscontroles of het harmoniseren van velden. De platinum-laag tenslotte bevat businessgerichte, samengevoegde datasets die rechtstreeks gebruikt worden voor rapportering en analyses, zoals onder meer in Power BI. Door de groei van het aantal bronnen, transformaties en rapporten is deze omgeving in de loop der tijd steeds complexer geworden, met talloze onderlinge afhankelijkheden tussen tabellen, modellen en rapportages.

In zo'n context-intensieve omgeving wordt het voor individuele medewerkers onhaalbaar om op basis van geheugen of losse documentatie een volledig overzicht te bewaren van de dataflows. De literatuur rond metadata management en governance benadrukt dat in dergelijke gedistribueerde en schaalbare omgevingen een gestructureerde aanpak rond data lineage cruciaal is om transparantie, herleidbaarheid en foutopsporing te ondersteunen. De complexiteit van het lakehouse bij VLAIO creëert dus een duidelijke nood aan betrouwbare lineage, zowel om de impact van wijzigingen transparanter en beter herleidbaar te maken als om de interne governance en controleerbaarheid van rapporten te versterken.

## 4.2. Basis-lineage in Databricks en Unity Catalog

Databricks en de bijhorende Unity Catalog voorzien in principe in een vorm van technische lineage, waarbij op basis van querygeschiedenis en metadata kan worden afgeleid welke tabellen door welke bewerkingen met elkaar verbonden zijn. In de praktijk wordt deze functionaliteit binnen VLAIO slechts beperkt ingezet. Tijdens afstemmomenten werd aangegeven dat lineage in Databricks "niet beschikbaar of niet gemakkelijk beschikbaar" is voor de doorsnee gebruiker, en dat er bovendien een tijdslimiet zit op de historiek die wordt bijgehouden. Daardoor is de zichtbaarheid van afhankelijkheden in de Databricks-omgeving onvolledig en sterk afhankelijk van wie weet waar de lineage-view zich bevindt en hoe deze juist moet worden gebruikt.

Daarnaast is de beschikbare lineage in Databricks voornamelijk table-level en beperkt tot de workloads binnen het platform zelf. Cruciale schakels, zoals de stap van platinum-datasets naar Power BI rapporten, behoren niet tot het standaardbeeld dat Unity Catalog aanbiedt. In de besprekingen werd expliciet benoemd dat vooral de sprong van Databricks naar Power BI en van raw naar gold- of platinum-data het moeilijkst te reconstrueren is, onder meer door naamswijzigingen, samenvoegingen en complexe transformaties. Zonder een geïntegreerde, end-to-end lineage moeten medewerkers terugvallen op handmatig zoeken in notebooks en code, wat tijdrovend en foutgevoelig is. Dat maakt de ingebouwde Databricks-lineage weliswaar nuttig als bouwsteen, maar ontoereikend als enige bron voor impactanalyses op organisatieniveau.

## 4.3. Impactanalyses bij VLAIO: definitie, triggers en rol van dataherkomst

Impactanalyses spelen een centrale rol in het datagedreven werken bij VLAIO. In essentie wordt in een impactanalyse onderzocht welke gevolgen een wijziging in databronnen, datamodellen of transformatieprocessen heeft op datasets en rapporten. Typische triggers zijn bijvoorbeeld aangekondigde wijzigingen in bronsystemen (velden die verdwijnen of een andere betekenis krijgen) en interne initiatieven om stermodellen te herontwerpen, bijvoorbeeld om rapportering te vereenvoudigen of nieuwe businessvereisten te ondersteunen.

In beide gevallen is het doel om vooraf in kaart te brengen welke datasets, berekeningen en rapporten afhankelijk zijn van de betrokken velden of tabellen, en welke aanpassingen gepland moeten worden voordat de wijziging effectief wordt doorgevoerd. De resultaten van zo'n analyse worden nadien vertaald naar concrete acties voor data-engineers, analisten en Power BI-ontwikkelaars. De huidige impactanalyse-documenten leggen deze redenering vast en beschrijven vaak een as-is en to-be situatie, maar steunen voor de onderliggende datastromen in belangrijke mate op manuele reconstructie en domeinkennis.

Het nut van impactanalyses hangt daarmee sterk af van het zicht op onderliggende afhankelijkheden: zonder overzicht van welke databronnen, tabellen en rapporten door dezelfde wijziging geraakt kunnen worden, is het moeilijk om impact betrouwbaar en efficiënt in te schatten. In de huidige situatie vormt het ontbreken van een centraal en herhaalbaar overzicht van deze afhankelijkheden een belangrijke beperking.

Voor technische impactanalyses ligt de meerwaarde van lineage vooral in het verminderen van manueel opzoekwerk en het verkleinen van de afhankelijkheid van impliciete kennis bij collega's. In deze bachelorproef wordt dit effect niet afzonderlijk gemeten, aangezien de technische documenten en bijhorende analysepraktijk slechts door een beperkte groep worden gebruikt. Bovendien is de meerwaarde van lineage in die context relatief evident: een expliciet overzicht van afhankelijkheden maakt het eenvoudiger om betrokken datasets en rapporten te identificeren. Daarom richt deze studie zich naar een breder doelpubliek.

De evaluatie in Hoofdstuk 6 onderzoekt daarom in welke mate het lineage-overzicht ook voor een ruimere groep rapportgebruikers, bouwers en technische rollen bijdraagt aan het beter begrijpen en inschatten van de impact van wijzigingen op

rapporten. Daarbij wordt nagegaan in welke mate extra inzicht in dataherkomst en afhankelijkheden leidt tot meer begrijpbaarheid, herleidbaarheid en vertrouwen in gerapporteerde cijfers.

## 4.4. Huidige pijnpunten in het impactanalyseproces

De grootste pijnpunten in de huidige situatie bij VLAIO hebben te maken met het ontbreken van een centrale, betrouwbare lineage-view over de volledige keten van bronsystemen tot Power BI-rapporten. Zonder geïntegreerde lineage moeten analisten, rapportbouwers en data-engineers telkens opnieuw velden en tabellen manueel volgen doorheen de verschillende lagen. Dat gebeurt onder meer door notebooks en code door te zoeken, bestandsnamen en kolomnamen te matchen, en collega's te raadplegen die mogelijk weten waar bepaalde velden nog gebruikt worden. Tijdens afstemmomenten werd expliciet vermeld dat men een veld regelmatig ter sprake brengt binnen het team om na te gaan of iemand weet of en waar het gebruikt wordt, wat illustreert hoe sterk het huidige zicht op dataherkomst afhangt van individuele herinneringen en informele communicatie.

De moeilijkste afhankelijkheden om te achterhalen zijn precies die stappen waar de standaard tools geen volledig beeld geven, zoals de sprong van Databricks naar Power BI, waar datasets en rapporten opnieuw andere benamingen en structuren kunnen krijgen. Daardoor is het niet alleen tijdrovend om de volledige keten te reconstrueren in impactanalyses, maar blijft het ook voor rapportgebruikers moeilijk om bij wijzigingen snel te begrijpen welke cijfers en rapporten geraakt worden en op welke bronnen ze precies steunen.

Samengevat leidt de huidige situatie tot lange doorlooptijden bij wijzigingen, een reëel risico op menselijke fouten en een sterke afhankelijkheid van specifieke personen met bepaalde domeinkennis. Precies die informatie die voor zowel impactanalyses als het dagelijks interpreteren en uitleggen van rapporten cruciaal is, namelijk een herbruikbaar overzicht van welke databronnen, tabellen en rapporten met elkaar verbonden zijn, ontbreekt de dag van vandaag nog in een centrale, doorzoekbare vorm. De proof-of-concept in deze bachelorproef vertrekt expliciet vanuit deze lacune.

## 4.5. Huidige basis-lineage met OpenMetadata en lacunes richting Power BI

Om deze knelpunten aan te pakken, wordt binnen VLAIO gewerkt met OpenMetadata als centraal metadata- en lineageplatform. In de literatuurstudie is OpenMetadata gepositioneerd als een open-source oplossing die data cataloging, governance en lineage combineert in één unified metadata-platform. Binnen de con-

text van deze bachelorproef wordt OpenMetadata gebruikt om metadata uit de Databricks-omgeving en andere relevante systemen te centraliseren en om een beter zicht te krijgen op de dataflows in het lakehouse. De OpenMetadata omgeving was reeds opgezet en de Databricks service was geconnecteerd. De eerste ingesties leveren een basis-lineage op voor tabellen en datasets binnen Databricks zelf, waarmee alvast een groot deel van de huidige fragmentatie wordt verminderd.

Een belangrijk hiaat is echter dat de lineage tussen platinum-datasets en de bijbehorende Power BI-datasets en -rapporten nog niet aanwezig is. Hoewel de Databricks-kant beter in beeld komt via OpenMetadata, blijft de laatste stap naar Power BI daarmee voorlopig nog buiten het gecentraliseerde lineagebeeld. In de gesprekken over impactanalyses werd net deze sprong expliciet als problematisch benoemd: gebruikers willen snel kunnen zien welke rapporten en visuals een bepaald veld of een bepaalde dataset gebruiken, en of dezelfde gegevens in verschillende rapporten onderliggend op dezelfde bron steunen. Zonder geïntegreerde Power BI-lineage blijft dit een manueel en foutgevoelig zoekproces. zowel bij impactanalyses als bij het beantwoorden van inhoudelijke vragen over rapporten.

Tijdens een bijkomend afstemmoment met het CC-Data team werd verkend in welke mate deze ontbrekende schakel tot op kolomniveau ingevuld kan worden. In theorie biedt OpenMetadata mogelijkheden om SQL-queries te analyseren of manueel kolomlineage vast te leggen via de API. In de praktijk bleken hier echter belangrijke beperkingen aan verbonden. De huidige logging in Databricks maakt bijvoorbeeld niet betrouwbaar zichtbaar of een query door een Power BI-rapport, een gebruiker in Databricks of een intern proces werd uitgevoerd. Daardoor kan een query niet eenduidig aan een specifiek Power BI-rapport worden gekoppeld, wat automatische kolomlineage richting rapportniveau sterk bemoeilijkt. Ook een manuele aanpak, waarbij per rapport kolomniveau-lineage wordt bijgehouden, werd in de afstemming als weinig haalbaar en onderhoudbaar beoordeeld.

Vanuit de context van VLAIO werd daarom bevestigd dat een benadering op tabelniveau vandaag het meest realistisch en bruikbaar is, terwijl de meer gedetailleerde kolomlineage een mogelijke vervolgstap blijft buiten de scope van deze bachelorproef. In het kader van deze studie wordt daarom specifiek onderzocht hoe OpenMetadata ingezet kan worden om die ontbrekende schakel op tabelniveau te leggen: Power BI-rapporten systematisch koppelen aan hun onderliggende platinum-datasets, zodzodat analyses rond wijzigingen, foutopsporing en uitleg aan rapportgebruikers niet langer hoeven te vertrekken van losse inschattingen en verspreide kennis, maar kunnen steunen op een visueel, doorzoekbaar lineage-overzicht.

In het volgende hoofdstuk wordt onderzocht hoe deze aanpak concreet kan wor-

den uitgewerkt, aan de hand van onder meer de rapporten Krissteunster en Steunser om de meerwaarde van end-to-end lineage te illustreren, terwijl de onderliggende logica gericht is op een generieke en herbruikbare toepassing binnen het volledige Power BI-rapportagelandschap. Dit hoofdstuk schetst daarvoor de uitgangssituatie en de belangrijkste pijnpunten die de nood aan een betere lineage-oplossing onderbouwen. In het volgende hoofdstuk wordt beschreven hoe de proof-of-concept met OpenMetadata wordt opgezet om de huidige basis-lineage uit te breiden richting Power BI en zo zowel impactanalyses als het dagelijks gebruik en de interpretatie van rapporten beter te ondersteunen, terwijl Hoofdstuk 6 vervolgens evalueert in welke mate het gerealiseerde lineage-overzicht gebruikers effectief helpt om wijzigingen en hun impact beter te begrijpen.

# 5

# Proof-of-concept implementatie met OpenMetadata

## 5.1. Doel en positionering van de proof-of-concept

Zoals beschreven in Hoofdstuk 4 ontstaat de grootste zichtbaarheidskloof in de huidige lineageketen bij VLAIO tussen de platinum-datasets in de Databricks-lakehouse omgeving en de daarop gebaseerde Power BI-rapporten. Deze proof-of-concept (PoC) heeft als doel om die laatste stap expliciet te maken in OpenMetadata, door Power BI-metadata systematisch te koppelen aan bestaande tabellen in de vorm van OpenMetadata-entiteiten en daaruit een bruikbare lineageketen op te bouwen voor representatieve impactanalysecases, in het bijzonder rapporten gebaseerd op de Steunster- en Krissteunster-schema's. Dit zijn datasetmodellen in de vorm van een sterschema, die een overzicht geven van alle steun die een onderneming bij VLAIO vraagt, krijgt en geweigerd wordt, met daarbij relevante informatie over maatregelen en dossierkenmerken. Krissteunster is daarbij een uitbreiding van Steunster.

Hoewel de evaluatie en de illustratieve voorbeelden in dit hoofdstuk voornamelijk focussen op de Steunster/Krissteunster-rapporten, is de onderliggende aanpak bewust generiek opgezet. De naamgebaseerde mappingscripts zijn ontwikkeld voor de volledige set Power BI-datasets uit de export (momenteel 418 datasets) en leveren voor een aanzienlijk deel daarvan overeenkomsten met platinum-datasets. De proof-of-concept werd aanvankelijk getest op een beperkte subset van Steunster en Krissteunster-rapporten, maar de uitgewerkte mapping- en lineage-logica is in principe toepasbaar op alle Power BI-rapporten waarvoor een betrouwbare koppeling naar platinum-datasets beschikbaar is. De volledige end-to-end-flow, inclusief dashboardcreatie en het effectief aanmaken van lineage-edges, werd binnen deze

bachelorproef niet voor alle beschikbare Power BI REST-data uitgevoerd, aangezien dit veel uitvoeringstijd vergde en de werking van de PoC reeds voldoende was aangetoond met de geselecteerde testsubset.

De PoC is uitgewerkt als een reeks herbruikbare Pythonscripts en Jupyter-notebooks in een Git-repository. De kernfunctionaliteit bestaat uit:

- het opzetten en testen van een verbinding met de OpenMetadata-client
- het inlezen en verwerken van metadata over Power BI-datasets en -rapporten, en van een overzicht van platinum-datasets
- het genereren van mappings tussen Power BI-datasetnamen en onderliggende platinum-datasets op basis van een hulpscript
- het aanmaken van dashboard-entiteiten in OpenMetadata voor Power BI-rapporten
- het leggen van lineage-edges tussen platinum-tabellen en de aangemaakte dashboards

Alle implementatiestappen zijn opgezet met het oog op herbruikbaarheid voor andere datasets dan Steunster. Lokale configuratie (JWT-token, pad naar metadata-files) wordt daarom gescheiden gehouden van de generieke logica voor mapping en lineage-opbouw.

## 5.2. Technische omgeving en architectuur

De PoC maakt gebruik van de bestaande OpenMetadata-omgeving binnen VLAIO. De verbinding gebeurt via de publieke API-endpoint `https://omd.data-services-dev.vlaio.be/api`, met een JWT-token dat lokaal als omgevingsvariabele wordt ingelezen. Op basis daarvan wordt in het script `client_config.py` een OpenMetadata-client opgebouwd, die in de rest van de repository wordt hergebruikt om entiteiten op te vragen en te creëren. Deze client is een python SDK client, die ervoor zorgt dat je makkelijk kan interageren met de API van OpenMetadata zonder dat je zelf rechtstreekse HTTP-verzoeken moet gebruiken. De standaardservice voor Power BI-gerelateerde entiteiten is `VLAIO_POWERBI_TEST`. Deze service was reeds aangemaakt in OpenMetadata en indien dit niet het geval zou zijn, kan de service eenvoudig worden aangemaakt via de OpenMetadata-gebruikersinterface of via de Python-SDK.

De repository bevat daarnaast een aantal scripts die tijdens de ontwikkeling gebruikt werden om de interactie met de OpenMetadata-API stapsgewijs te verkennen en te valideren. Deze scripts vormen geen onderdeel van de uiteindelijke end-to-end-flow, maar hebben een belangrijke rol gespeeld in het opbouwen en testen van de kernfunctionaliteit:

- `client_config.py`: hulpfunctie om de OpenMetadata-client in te stellen en de verbinding te testen
- `create_dashboard.py`: voorbeeldscript dat laat zien hoe een dashboard-entiteit aangemaakt kan worden via de SDK
- `add_lineage_edge.py`: voorbeeldscript om een lineage-edge tussen twee bestaande entiteiten toe te voegen
- `get_table_by_id.py`: script om een tabel op te zoeken op basis van id of fully-qualified name (FQN) en het resultaat van de API-call te inspecteren

Hoewel OpenMetadata standaard een Power BI-connector aanbiedt voor het automatisch aanmaken van dashboards en lineage,[1] kon deze in de VLAIO-context niet gebruikt worden. De nodige rechten en rechtstreekse toegang tot de Power BI REST API ontbreken op het niveau waarop OpenMetadata draait, waardoor een directe connectorconfiguratie niet haalbaar was. In theorie zou lineage ook volledig manueel kunnen worden opgebouwd via de gebruikersinterface, maar voor het aantal datasets en rapporten in scope zou dit een zeer arbeidsintensieve en foutgevoelige werkwijze zijn. Om die redenen is in deze PoC gekozen voor een alternatieve aanpak, waarbij Power BI-metadata uit Databricks — die daar beschikbaar is als resultaat van Power BI REST-exports — via CSV-bestanden wordt ingelezen en vervolgens via de OpenMetadata-SDK programmatisch wordt omgezet naar dashboard-entiteiten en lineage-edges.

Voor de end-to-end-flow rond de Steunster-case wordt gewerkt met notebooks, in het bijzonder `openmetadata_lineage_from_yaml.ipynb`, waarin de volledige keten van gegevensinlees, mapping, dashboardcreatie en lineage-opbouw doorlopen wordt. Een aparte notebook (`cleanup_steunster_lineage_dashboards.ipynb`) ondersteunt het opschonen van testdashboards en test-lineage, zodat de omgeving proper gehouden kan worden tijdens het ontwikkelen en testen.

Tokens en andere geheimen worden niet in de notebooks zelf opgeslagen, maar via een lokale `.env`-configuratie ingelezen, zodat de code zelf herbruikbaar blijft zonder gevoelige informatie prijs te geven.

## 5.3. Datasets en metadata-bronnen

De PoC combineert drie soorten metadata-bronnen:

- Power BI-metadata in Databricks (tabellen met informatie over datasets en rapporten, gevoed via de Power BI REST API)

[1] Zie de officiële documentatie van OpenMetadata voor de Power BI-connector: https://docs.open-metadata.org/v1.12.x/connectors/dashboard/powerbi.

- een export van platinum-datasets uit de Databricks-lakehouseomgeving
- bestaande metadata in OpenMetadata voor Databricks-tabellen en Power BI-dashboards

De Power BI-kant wordt in deze PoC gerepresenteerd via CSV-bestanden die uit Databricks werden geëxporteerd:

- `PowerBI_Datasets.csv`: een lijst van Power BI-datasets met onder meer namen en ids;
- `PowerBI_Steunster_Datasets.csv`: één van de subsets van Power BI-datasets gebruikt voor het testen

Aan Databricks-zijde wordt gewerkt met:

- `All_Platinum_Datasets.csv`: een overzicht van alle platinum-datasets aanwezig in de databricks omgeving

De bedoeling is dus om alle PowerBI datastes te kopellen aan de bijhorende platinum datasets. Als deze mapping vastligt kan nadien correcte lineage toegeveogd worden. Hoewel in deze PoC gewerkt wordt met CSV-exports uit Databricks, is de gebruikte logica niet inherent afhankelijk van CSV-bestanden: in principe kan dezelfde mapping- en lineage-aanmaak ook rechtstreeks op de Databricks-tabellen worden toegepast, door de benodigde metadata direct uit de lakehouseomgeving lezen. In het kader van deze bachelorproef is gekozen voor CSV-exports als pragmatische oplossing binnen de beschikbare tijd en rechten.

Binnen OpenMetadata zelf zijn de Databricks-tabellen reeds geregistreerd via bestaande ingestietaken. De PoC voegt hieraan een extra laag toe: Power BI-dashboards en lineage-edges die laten zien welke platinum-tabellen de belangrijkste bron vormen voor een bepaald rapport.

**Afleiding van Power BI-rapporten uit Databricks.**
Omdat OpenMetadata in de huidige VLAIO-omgeving niet rechtstreeks kan verbinden met de Power BI REST API, werd gebruikgemaakt van de afgeleide Power BI-metadata die reeds onder vele tabellen in Databricks beschikbaar is (onder meer `powerbirestapi_report` en `powerbirestapi_dataset`). Deze tabellen waren niet vooraf gedocumenteerd voor het doel van lineage, waardoor eerst manueel onderzocht moest worden welke combinaties van kolommen en joins nodig waren om een bruikbaar overzicht van rapporten en bijbehorende datasets op te bouwen. Na het verkennen van de relevante tabellen werd onderstaande query opgesteld als basis om de Steunster-rapporten te extraheren:

**Listing 5.1:** Query om Power BI-rapporten en -datasets te selecteren uit Databricks

```
SELECT
    r.RapportNaam,
    r.WebUrl,
    -- r.RapportOmschrijving,
    d.DatasetNaam,
    r.RapportID,
    r.DatasetID
FROM ccdata_dev.silver.powerbirestapi_report r
JOIN ccdata_dev.silver.powerbirestapi_dataset d
ON r.DatasetID = d.DatasetID
WHERE d.DatasetNaam = 'VLAIO Steunster'
ORDER BY r.RapportNaam
LIMIT 20;
```

De kolom `RapportOmschrijving` werd hier bewust niet gebruikt, omdat deze in de praktijk vrijwel altijd leeg bleek en dus weinig meerwaarde had voor de PoC. Indien deze ingevuld is kan je deze ook meegeven aan OpenMetadata. Op basis van de queryresultaten werd een CSV-export gemaakt die vervolgens in de notebook werd ingelezen als input voor de mapping- en lineage-scripts. Dit was noodzakelijk omdat op het moment van de implementatie nog geen permissies beschikbaar waren om vanuit Databricks rechtstreeks met de OpenMetadata-API te verbinden. Conceptueel is de aanpak echter niet beperkt tot CSV-bestanden: dezelfde SQL-query kan in een latere fase rechtstreeks als bron dienen voor een geautomatiseerde lineageflow, waarbij de resultaten zonder tussenstap naar OpenMetadata worden geschreven.

In de query hierboven wordt gefilterd op `DatasetNaam = 'VLAIO Steunster'` om de eerste experimenten te focussen op één concrete dataset. Deze filter is niet strikt noodzakelijk: in principe kan hetzelfde patroon zonder deze voorwaarde worden toegepast op alle rapporten in de powerbirestapi-tabellen, waarna de generieke mappinglogica de koppeling naar de onderliggende platinum-datasets voor het volledige Power BI-landschap kan maken.

## 5.4. Mapping van Power BI-datasets naar platinum-datasets

### 5.4.1. Algemene mappingstrategie

De kern van de PoC is een generieke mappinglaag die Power BI-datasetnamen koppelt aan de onderliggende platinum-datasets. Deze mapping gebeurt niet via handmatig ingevulde lijsten, maar via een set heuristieken die de namen in beide domeinen op verschillende manieren met elkaar vergelijkt. De implementatie is opgesplitst in twee scripts:

- `_build_mapping.py`: bouwt een basis-mapping tussen de volledige lijst van

Power BI-datasets en de platinum-datasetlijst

- `_build_mapping_strict.py`: verfijnt de mapping en filtert op de meest betrouwbare matches

De scripts voeren eerst een normalisatie van namen uit (bijvoorbeeld lowercasing, verwijderen van speciale tekens, hanteren van consistentie bij camelCase en enkele uitzonderingen en passen vervolgens verschillende heuristieken toe om mogelijke matches te scoren.

In de context van deze bachelorproef wordt de mappinggenerator vooral gebruikt als hulpmiddel om een eerste, zo volledig mogelijke basisversie van de YAML configuratie voor Power BI–platinum-mapping op te bouwen en om manuele mappingarbeid te beperken. Het is niet de bedoeling dat deze scripts één-op-één als verplicht onderdeel van de toekomstige operationele processen bij VLAIO worden overgenomen, maar eerder dat ze aantonen hoe een naamgebaseerde aanpak kan helpen om een correct startpunt voor verdere verbetering te creëren.

### 5.4.2. Heuristieken en outputstructuur

De mappinglogica combineert verschillende naamgebaseerde vergelijkingsstrategieën, zoals exacte matching, deelstringvergelijkingen, fuzzy matching en tokengebaseerde vergelijkingen. Op basis van de gecombineerde scores worden potentiële koppelingen tussen Power BI- en platinum-datasets automatisch geclassificeerd naar betrouwbaarheid. De resultaten worden vervolgens weggeschreven naar aparte CSV-bestanden, zodat duidelijke matches rechtstreeks gebruikt kunnen worden en twijfelgevallen apart beschikbaar blijven voor eventuele manuele controle.

De mapping-output ondersteunt ook multi-mapping. Elke Power BI-dataset kan, indien nodig, aan meerdere platinum-datasets gekoppeld worden. De kolom `platinum_datasets` bevat dan een lijst van kandidaten, en `match_count` geeft het aantal matches aan. Dergelijke composite-situaties krijgen een aparte status, `confirmed_multi`, zodat downstream-logica hiermee rekening kan houden. Een voorbeeld hiervan is `Krissteunster-Steunster Composite model` die gemapt moet worden naar zowel Steunster als Krissteunster.

In de meest recente run verwerkte de mappinggenerator 418 Power BI-datasets, waarvan 117 als `confirmed` en 4 als `confirmed_multi` werden geclassificeerd. De overige 297 datasets bleven `unmatched`. Dat is niet noodzakelijk een tekortkoming van de mappinglogica: veel Power BI-datasets hebben geen directe of zinvolle tegenhanger in de platinum-laag en kunnen daarom normaal gezien niet gekoppeld

worden. Deze niet-gematchte gevallen vragen wel een manuele controle om te onderscheiden tussen terecht niet-koppelbare datasets en uitzonderingen waarvoor de heuristieken nog verfijnd kunnen worden.

**Voorbeeld van mapping-output (CSV).**
Onderstaand fragment illustreert hoe de output van het mappingscript eruitziet in `PowerBI_to_Platinum_mapping_confirmed.csv`. Hieruit blijkt dat de naam van een Power BI-dataset niet noodzakelijk exact hoeft overeen te komen met de naam van de bijhorende platinum-dataset om toch tot een correcte koppeling te komen. De gegenereerde mapping dient daarbij vooral als een eerste, reproduceerbare basis die manueel werk vermindert. Vooraleer deze mappings worden omgezet naar de YAML-configuratie die effectief gebruikt wordt voor het aanmaken van lineage, moeten ze uiteraard manueel nagekeken worden.

| Power BI-dataset | Platinum-dataset(s) | Aantal | Score | Status |
|---|---|---|---|---|
| Bedrijventerreinenster | bedrijventerreinenster | 1 | 1.000 | confirmed |
| Contactenster | contactenster | 1 | 1.000 | confirmed |
| KRISsteunster | krissteunster | 1 | 1.000 | confirmed |
| Krissteunster–Steunster Composite model | krissteunster;steunster | 2 | 0.990 | confirmed_-multi |
| Corona – Heropstartlening | r_coronaheropstartle-ning | 1 | 0.980 | confirmed |

**Tabel 5.1:** Verkort fragment uit `PowerBI_to_Platinum_mapping_confirmed.csv`.

**Voorbeeld van Power BI-datasetmappings (YAML).**
Dat laatste is bijvoorbeeld het geval in het onderstaande fragment voor `Epplus betalingen`. Deze Power BI-dataset wordt enerzijds nog steeds logisch gekoppeld aan de platinum-dataset `r_epplus`, maar anderzijds wordt ook expliciet de tabel `epp_betalingen` meegegeven. Hierdoor verwijst de lineage in dit geval niet naar alle fact- of brontabellen binnen `r_epplus`, maar enkel naar de concrete tabel waarvoor voldoende zekerheid bestaat dat ze effectief in het rapport gebruikt wordt. De YAML-structuur laat dus zowel generieke mappings op datasetniveau als meer precieze mappings op tabelniveau toe, afhankelijk van de hoeveelheid beschikbare metadata.

**Listing 5.2:** Fragment uit PowerBI_Dataset_Mappings.yml

```
- PBIDataset: VLAIO Steunster
  target_datasets:
    - steunster

- PBIDataset: KRISsteunster
  target_datasets:
    - krissteunster

- PBIDataset: Krissteunster-Steunster Composite model
  target_datasets:
    - krissteunster
    - steunster

- PBIDataset: Dataset PBIDatasetsMetRollen
  target_datasets:
    - r_pbidatasetsmetrollen

- PBIDataset: Epplus betalingen
  target_datasets:
        - r_epplus
  target_tables:
    - lz02-d-dbw-ccdata-main.platinum_dev.r_epplus.epp_betalingen
```

**Voorbeeld van platinum-datasetmappings (YAML).**
Aangezien lineage in OpenMetadata volgens de gangbare aanpak op tabelniveau wordt vastgelegd, volstaat het niet om enkel een koppeling te maken tussen een Power BI-dataset en een logische platinum-dataset. Daarom werd aanvullend een manuele mapping opgesteld waarin per platinum-dataset wordt vastgelegd welke concrete tabellen als meest relevante bron voor de lineage beschouwd worden. Daarbij wordt in de eerste plaats gekozen voor facttabellen wanneer die beschikbaar zijn, en anders voor de belangrijkste tabellen binnen de betrokken dataset.

In `Platinum_Dataset_Mappings.yml` worden de logische platinum-datasets verder vertaald naar één of meerdere technische tabel-FQN's in Databricks. Daarbij wordt bewust met fully qualified names (FQN's) gewerkt, omdat deze niet alleen eenduidig verwijzen naar de juiste tabel binnen de Databricks-omgeving, maar ook noodzakelijk zijn om de overeenkomstige tabelentiteiten correct op te zoeken en te gebruiken in OpenMetadata. Deze YAML-configuratie is makkelijk uitbreidbaar en aanpasbaar. Nieuwe datasets of bijkomende tabellen kunnen zonder aanpassing van de onderliggende scriptlogica worden toegevoegd, terwijl bestaande mappings ook eenvoudig verfijnd kunnen worden wanneer extra domeinkennis beschikbaar komt of de datamodellen wijzigen.

**Listing 5.3:** Fragment uit Platinum_Dataset_Mappings.yml

```
- dataset: krissteunster
```

```
    target_tables:
      - lz02-d-dbw-ccdata-main.platinum_dev.krissteunster.f_steun
      - lz02-d-dbw-ccdata-main.platinum_dev.krissteunster.f_steunster
      - lz02-d-dbw-ccdata-main.platinum_dev.krissteunster.
          f_steunster_toegevoegdewaarde

  - dataset: steunster
    target_tables:
      - lz02-d-dbw-ccdata-main.platinum_dev.steunster.f_steun
```

## 5.5. Dashboards en lineage in OpenMetadata

### 5.5.1. End-to-end-flow voor Steunster

De end-to-end-aanpak voor de Steunster-rapporten bestaat uit meerdere opeenvolgende stappen. Niet al deze stappen worden in de notebook `steunster_open-metadata_lineage_from_yaml.ipynb` zelf uitgevoerd. De voorbereiding gebeurt deels vooraf en omvat het verzamelen van de nodige Power BI-metadata, het genereren en manueel valideren van de mappings, en het opstellen van de YAML-configuraties. De notebook gebruikt deze voorbereide input vervolgens om de effectieve OpenMetadata-flow uit te voeren, namelijk het opzoeken van de juiste tabel-entiteiten, het aanmaken van dashboard-entiteiten en het leggen van de overeenkomstige lineage-relaties. De volledige flow bestaat uit:

1. verzamelen en voorbereiden van de nodige Power BI-metadata;
2. bepalen welke Power BI-dataset aan elk geselecteerd rapport gekoppeld is;
3. genereren en valideren van mappings tussen Power BI-datasets en platinum-datasets;
4. vastleggen van de relevante platinum-tabellen in YAML-configuratie;
5. opzoeken van de corresponderende tabel-entiteiten in OpenMetadata via hun fully qualified name of id;
6. aanmaken van dashboard-entiteiten in OpenMetadata voor de relevante Power BI-rapporten;
7. aanmaken van lineage-edges van de geselecteerde platinum-tabellen naar de aangemaakte dashboards.

De focus ligt op lineage op tabelniveau: voor elk rapport wordt minstens één lineage-edge gelegd vanaf de belangrijkste platinum-tabel, vaak de facttabel(s) naar het dashboard, aangevuld met extra edges bij samengestelde datasets. Op die manier ontstaat ereen visueel traceerbare keten van bronsystemen via medallion-lagen (bronze, silver, platinum) tot en met de rapportages.

### 5.5.2. Belangrijkste notebook-code

Onderstaande fragmenten tonen de kernlogica uit de notebook: het opzetten van de OpenMetadata-connectie, het inlezen van rapporten en YAML-mappings en het aanmaken van dashboards en lineage-edges. Enkel de belangrijkste code wordt weergegeven; imports, debug-prints, uitvoercontroles en enkele helperfuncties zijn weggelaten voor de leesbaarheid.

#### OpenMetadata-connectie

Dit codefragment initialiseert de verbinding met OpenMetadata en zorgt ervoor dat de notebook geauthenticeerd kan communiceren met het metadata-platform. Eerst wordt een JWT-token uit de omgevingsvariabelen geladen, waarna de connectieparameters voor de OpenMetadata-server en de dashboardservice worden ingesteld. Tot slot wordt gecontroleerd of de verbinding succesvol tot stand komt, zodat de volgende stappen enkel worden uitgevoerd wanneer de metadata-omgeving bereikbaar is.

**Listing 5.4:** OpenMetadata clientconnectie

```
# (hier worden alle imports en omgevingsvariabelen geladen)
jwt = os.getenv("JWT")

# Hier wordt de OpenMetadata-host en de dashboardservice ingesteld
OM_HOST = "https://omd.data-services-dev.vlaio.be/api"
DASHBOARD_SERVICE = "VLAIO_POWERBI_TEST"

# Serverconfiguratie voor de OpenMetadata-client en eronder de SDK-client
server_config = OpenMetadataConnection(
    hostPort=OM_HOST,
    authProvider="openmetadata",
    securityConfig=OpenMetadataJWTClientConfig(jwtToken=jwt),)

# initialisatie ometa-client en SDK-client
metadata = OpenMetadata(server_config)
configure(host=OM_HOST, jwt_token=jwt)
```

#### Inlezen van rapporten en YAML-mappings

In volgend codefragment worden enerzijds de Power BI-rapporten uit een CSV-bestand ingelezen en anderzijds de mappingbestanden in YAML-formaat verwerkt. Vervolgens worden hulpfuncties gedefinieerd om sleutels te normaliseren, lijsten van tabellen op te bouwen en dubbele waarden te verwijderen met behoud van volgorde. Op basis daarvan wordt een resolver opgebouwd die per Power BI-dataset de juiste brontabellen bepaalt, met prioriteit voor rechtstreeks opgegeven tabellen en een fallback via gekoppelde platinum-datasets. Het inladen van de Power BI-data, de mappings en de hulpfuncties zijn hier weggelaten.

**Listing 5.5:** PBI-data en mappings inladen en verwerken

```
POWERBI_MAPPING_PATH = "PowerBI_Dataset_Mappings.yml"
PLATINUM_MAPPING_PATH = "Platinum_Dataset_Mappings.yml"

# Hier worden twee dictionaries aangemaakt:
# 1) Power BI naar platinumdataset
power_bi_map = {}
for item in power_bi_yaml.get("datasets", []):
    pbi_name = str(item.get("PBIDataset", "")).strip()
    if not pbi_name:
        continue
    power_bi_map[normalize_key(pbi_name)] = {
        "target_tables": to_str_list(item.get("target_tables", [])),
        "target_datasets": to_str_list(item.get("target_datasets", [])),}

# 2) platinumdataset naar correcte tabel(len)
platinum_map = {}
for item in platinum_yaml.get("datasets", []):
    dataset_name = str(item.get("dataset", "")).strip()
    if not dataset_name:
        continue
    platinum_map[normalize_key(dataset_name)] = to_str_list(item.get("
        target_tables", []))
```

Na het opbouwen van de opzoektabellen wordt de logica gedefinieerd om de effectieve technische brontabellen te bepalen. De functie `resolve_source_table_fqns` gebruikt hierbij een prioriteitsregeling: er wordt eerst gezocht naar direct gedefinieerde tabellen in de mapping, en bij afwezigheid daarvan wordt de koppeling gelegd via de overkoepelende platinum-datasets. Dit is zo geïmplementeerd voor de uitzonderlijke gevallen waarin wel meegegeven wordt welke specifieke tabel uit het schema gebruikt wordt. Meestal ontbreekt deze informatie en wordt gemapt naar de belangrijkste tabel(len). Tot slot wordt een hulpfunctie geïmplementeerd die de OpenMetadata-SDK aanroept om de effectieve tabelentiteiten op te zoeken op basis van hun Fully Qualified Name, die is opgebouwd als `database-service.database.schema.table`.

**Listing 5.6:** Functies voor het opzoeken van de brontabel

```
# Bepaal de bron-tabellen voor een Power BI-dataset met volgende prioriteit:
# 1. direct opgegeven target_tables in de Power BI-YAML
# 2. target_datasets uit de Power BI-YAML, vertaald via de Platinum-YAML
def resolve_source_table_fqns(dataset_name: str) -> list[str]:
    mapping = power_bi_map.get(normalize_key(dataset_name))
    if not mapping:
        return []

# Gebruik directe target_tables wanneer deze expliciet aanwezig zijn.
```

```
    direct_tables = mapping.get("target_tables", [])
    if direct_tables:
        return unique_preserve_order(direct_tables)

# Gebruik anders target_datasets en vertaal die naar tabel-FQNs.
    resolved = []
    for target_dataset in mapping.get("target_datasets", []):
        resolved.extend(platinum_map.get(normalize_key(target_dataset), []))
    return unique_preserve_order(resolved)

# Functie om een tabel op te halen via de fully-qualified name
def get_table_by_fqn(fqn: str):
    try:
        return Tables.retrieve_by_name(fqn)
    except Exception:
        return None
```

### Aanmaken van dashboards

Vervolgens worden de ingelezen Power BI-rapporten omgezet naar dashboard-entiteiten in OpenMetadata. Daarbij wordt eerst gecontroleerd of een dashboard reeds bestaat op basis van het rapport-ID of de URL, zodat dubbele creatie vermeden wordt. Indien nog geen overeenkomstig dashboard aanwezig is, wordt een nieuwe dashboard-entiteit aangemaakt en worden de relevante identificatoren en resultaten bijgehouden voor verdere verwerking. Het is mogelijk dat verschillende rapporten verwijzen naar dezelfde Power BI-URL, dus de optie `CREATE_IF_WEB_URL_NOT_EXISTS` staat idealiter op `False`. Hierdoor wordt voor elk rapport met een uniek id een dashboard gemaakt.

In onderstaande code worden de bestaande dashboards op OpenMetadata opgehaald en bijgehouden op URL en id. Deze worden later gebruikt om na te kijken of al dan niet een dashboard is aangemaakt voor een rapport, om dubbels te voorkomen.

**Listing 5.7:** Opzoeken bestaande dashboards

```
# Bepaal hoe bestaande dashboards gedetecteerd worden:
# False = controle op basis van RapportID
# True = controle op basis van WebUrl
CREATE_IF_WEB_URL_NOT_EXISTS = False

# (Hier staan enkele hulpfuncties)

# Indexeer bestaande dashboards om duplicaten te vermijden.
existing_by_url = {}
existing_by_report_id = {}

for dashboard in Dashboards.list_all():
    dashboard_url = normalize_url(to_plain_str(getattr(dashboard, "sourceUrl", "")
```

```
        ))
    dashboard_report_id = extract_report_id(dashboard_url)

if dashboard_url and dashboard_url not in existing_by_url:
    existing_by_url[dashboard_url] = dashboard

if dashboard_report_id and dashboard_report_id not in existing_by_report_id:
    existing_by_report_id[dashboard_report_id] = dashboard
```

Vervolgens wordt er voor elk rapport uit de bronbestanden een dashboard-entiteit aangemaakt via de OpenMetadata-SDK. Het is belangrijk hierbij op te merken dat deze entiteit in OpenMetadata dient als een metadatarepresentatie of een proxy en niet het werkelijke dashboard bevat. De entiteit krijgt standaard de naam van het bijbehorende Power BI-rapport. Door bij de creatie aanvullende parameters zoals een omschrijving en de `sourceUrl` mee te geven, wordt de traceerbaarheid vergroot en kan een gebruiker vanuit de OpenMetadata-interface direct navigeren naar het effectieve rapport in de Power BI-service. Ten slotte wordt ook een dataframe opgebouwd en weergegeven zodat zichtbaar is welke dashboards aangemaakt of overgeslagen zijn; deze code is hier weggelaten.

**Listing 5.8:** Dashboards maken en posten naar OpenMetadata

```
# Alle rapporten van de Power BI REST API worden doorlopen
for _, row in df.iterrows():
    rapport_naam = str(row["RapportNaam"]).strip()
    web_url = str(row["WebUrl"]).strip()
    dataset_naam = str(row["DatasetNaam"]).strip()
    rapport_id = str(row["RapportID"]).strip()
    dataset_id = str(row["DatasetID"]).strip()

# Zoek de gekoppelde brontabellen op via de YAML-resolver
    source_fqns = resolve_source_table_fqns(dataset_naam)

    normalized_url = normalize_url(web_url)
    normalized_report_id = rapport_id.lower()
    existing_dashboard = None

# Kies de gewenste controlelogica voor reeds bestaande dashboards
    if CREATE_IF_WEB_URL_NOT_EXISTS:
        existing_dashboard = (created_by_url.get(normalized_url) or
            existing_by_url.get(normalized_url))
        check_mode = "WebUrl"
    else:
        existing_dashboard = (created_by_report_id.get(normalized_report_id) or
            existing_by_report_id.get(normalized_report_id))
    check_mode = "RapportID"

# Gebruik een bestaand dashboard wanneer dat al aanwezig is
    if existing_dashboard is not None:
```

```
        dashboard_id = existing_dashboard.id
        dashboard_fqn = to_plain_str(existing_dashboard.fullyQualifiedName)
        dashboard_status = f"existing ({check_mode} al aanwezig)"
# Maak anders een nieuwe dashboardentiteit aan
    else:
    request = CreateDashboardRequest(
        name=rapport_naam,
        displayName=rapport_naam,
        service=DASHBOARD_SERVICE,
        description=f"Dashboard aangemaakt vanuit CSV voor dataset {dataset_naam}.
            ",
        sourceUrl=web_url,)

    try:
        dashboard = Dashboards.create(request)
        dashboard_id = dashboard.id
        dashboard_fqn = to_plain_str(dashboard.fullyQualifiedName)
        dashboard_status = "created"

        created_by_url[normalized_url] = dashboard
        if normalized_report_id:
            created_by_report_id[normalized_report_id] = dashboard
    except Exception as exc:
        dashboard_id = None
        dashboard_fqn = None
        dashboard_status = f"error: {exc}"
```

### Aanleggen van lineage-edges

In dit laatste codefragment worden de lineage-relaties tussen de gevonden brontabellen en de aangemaakte dashboards toegevoegd. Voor elke gekoppelde tabel wordt nagegaan of de entiteit bestaat en of dezelfde relatie nog niet eerder werd aangemaakt, zodat dubbele lineage-edges vermeden worden. Het resultaat is een expliciete representatie van welke databronnen een bepaald Power BI-rapport voeden binnen OpenMetadata. De logging van deze code is opnieuw weggelaten; deze bouwt per verwerkt rapport een dataframe op met zowel de status van het aanmaken van het dashboard als de lineage-edge(s).

**Listing 5.9:** Lineage aanleggen in OpenMetadata

```
lineage_results = []

for _, row in dashboards_df.iterrows():
    RapportNaam = row["RapportNaam"]
    DatasetNaam = row["DatasetNaam"]
    RapportID = row["RapportID"]
    DatasetID = row["DatasetID"]
    WebUrl = row["WebUrl"]
```

```
    source_fqns = row["mapped_source_fqns"] if isinstance(row["mapped_source_fqns"
        ], list) else []
    dashboard_status = row["dashboard_status"]
    dashboard_fqn = row["dashboard_fqn"]
    dashboard_id = row["dashboard_id"]

    has_dashboard = pd.notna(dashboard_id)
    table_statuses = []
    created_count = 0

    if has_dashboard and source_fqns:
        for source_fqn in source_fqns:
            source_table = get_table_by_fqn(source_fqn)
            if not source_table:
                table_statuses.append(f"skipped:not_found:{source_fqn}")
                continue

            pair_key = f"{source_table.id}->{dashboard_id}"
            if pair_key in seen_lineage_pairs:
                table_statuses.append(f"skipped:duplicate_pair:{source_fqn}")
                continue
            try:
                req = AddLineageRequest(
                    edge=EntitiesEdge(
                        description=f"{DatasetNaam} voedt Power BI-rapport '{
                            RapportNaam}'",
                        fromEntity=EntityReference(id=source_table.id, type="table
                            "),
                        toEntity=EntityReference(id=dashboard_id, type="dashboard"
                            ),
                        lineageDetails=LineageDetails(
                            source="Manual",
                            description="Automatisch toegevoegd via notebook op
                                basis van YAML-mappings")))
                metadata.add_lineage(data=req)
                seen_lineage_pairs.add(pair_key)
                created_count += 1
                table_statuses.append(f"created:{source_fqn}")
            except Exception as exc:
                table_statuses.append(f"error:{source_fqn}:{exc}")
# (hier worden lineage_results en logging opgebouwd)
```

### 5.5.3. Lineage voor composite-modellen

In gevallen waar een Power BI-model meerdere platinum-datasets combineert, maakt de PoC gebruik van de `confirmed_multi`-status. De mapping-output bevat dan meerdere platinum-datasets in de kolom `platinum_datasets`, en de lineage-logica genereert voor elk van deze datasets een aparte edge richting hetzelfde dashboard. Hierdoor wordt zichtbaar dat een rapport afhankelijk is van meer dan één dataset in de platinum-laag, wat belangrijk is voor impactanalyses: een wijzi-

ging in één van de onderliggende datasets kan potentieel invloed hebben op het volledige rapport.

De Krissteunster-Steunster-case is hiervan een concreet voorbeeld. De composite Power BI-dataset wordt gekoppeld aan zowel een `krissteunster`- als een `steunster`-platinumdataset, zodat analisten in OpenMetadata onmiddellijk zien dat wijzigingen in één van beide datasets impact kunnen hebben op dezelfde rapportage.

## 5.6. Beheer en opschoning van testartefacten

Tijdens de iteratieve ontwikkeling van de PoC is het noodzakelijk om dashboards en lineage-edges regelmatig opnieuw te creëren en te verwijderen. Hiervoor wordt de notebook `cleanup_steunster_lineage_dashboards.ipynb` gebruikt.

In deze notebook worden de aangemaakte dashboards op basis van naam of id opgezocht. Omdat naamnormalisatie soms leidt tot ambiguïteit, wordt de delete-operatie bij voorkeur uitgevoerd op basis van de unieke id die in OpenMetadata aan elk dashboard verbonden is. De notebook verwijdert vervolgens zowel de dashboard-entiteiten als de bijhorende lineage-edges, zodat er geen verouderde of dubbele relaties in de metadata achterblijven.

Praktisch kwamen tijdens het testen enkele terugkerende aandachtspunten naar voren:

- JWT-tokens vervallen regelmatig tijdens langere sessies in de notebookomgeving. In dat geval moet de kernel herstart worden en de configuratiecel opnieuw uitgevoerd worden, zodat de client opnieuw met een geldig token kan werken.
- De scripts en notebooks zijn gevoelig voor bestandslocaties. Sommige flows verwachten CSV's in een `Datasets`-submap, andere in de root van de repository. In de documentatie wordt daarom expliciet vermeld welke paden voor welke notebook gebruikt worden, om reproductieproblemen te voorkomen.

## 5.7. Beperkingen en randvoorwaarden

De beschreven implementatie is bewust opgezet als proof-of-concept en kent een aantal belangrijke beperkingen die van invloed zijn op de interpretatie van de resultaten.

### 5.7.1. Beperkingen van de naamgebaseerde mapping

Ten eerste is de mappinglogica volledig naamgebaseerd. Hoewel de gebruikte naamgebasseerde regels in veel gevallen goede resultaten opleveren, blijft de betrouwbaarheid afhankelijk van consistente en informatieve naamgeving aan zowel Power BI- als Databricks-zijde. Datasets met zeer generieke of sterk afwijkende namen blijven `unmatched` en vallen buiten de scope van de huidige PoC. Een bijkomend gevolg van het ontbreken van een bruikbare Power BI-connector is dat de PoC voor zijn mappings volledig steunt op de Power BI-REST-API metadata in Databricks en de daaruit afgeleide data. In de huidige implementatie worden alle unieke Power BI-datasets uit deze exports opgenomen in de mapping-flow en vergeleken met de lijst van platinum-datasets. Voor de datasets die vandaag in scope zijn, levert dit in combinatie met de gebruikte naamgebasseerde regels een set mappings op die in de praktijk nagenoeg volledig correct is.

### 5.7.2. Rol en onderhoud van de YAML-mappings

In de huidige opzet vormen de gegenereerde YAML-mappings naast de lineage logica het belangrijkste resultaat voor VLAIO: zij leggen vast welke Power BI-datasets aan welke platinum-tabellen gekoppeld worden en worden rechtstreeks gebruikt in de end-to-end-workflows. De Python-scripts voor mapping zijn in de eerste plaats onderzoeks- en ondersteunende tools om deze YAML sneller en consistenter op te bouwen. VLAIO kan er in de toekomst voor kiezen om deze scripts al dan niet opnieuw te gebruiken, maar het is even goed mogelijk om de YAML zelf aan te passen wanneer er nieuwe datasets bijkomen of gewijzigd worden. In de meest recente versie van de YAML-workflows dekken de gegenereerde mappings vrijwel alle relevante rapporten binnen de PoC-scope. Om deze workflows in de toekomst correct te laten blijven werken, is het wel noodzakelijk dat nieuwe of aangepaste Power BI-datasets een naam krijgen die inhoudelijk aansluit bij de corresponderende platinum-dataset. Wanneer datasetnamen sterk afwijken of generiek geformuleerd zijn, neemt de kans toe dat ze niet automatisch gematcht worden en manuele aanvulling of bijsturing van de mapping nodig is.

### 5.7.3. Beperkingen van lineage op kolomniveau

Ten tweede is de lineage in deze PoC bewust beperkt tot tabelniveau. Nadat een tabel-level lineage is aangelegd op OpenMetadata is het mogelijk om de lineage uit te breiden tot op kolom-nieveau. Dit zou zorgen voor een beter inzicht, aangezien je voor een waarde in een rapport de specifieke kolom(men) zou kunnen nagaan waaruit deze is opgebouwd, alsook de onderliggende transformaties. Nadat er succesvol tabel lineage was voorzien, werd er onderzocht hoe dit uitbreidbaar is tot op kolomnieveau. Dit is mogelijk op twee manieren. De eerste is opnieuw een

mapping aanmaken die een bronkolom met een eindkolom verbindt. Aangezien er op kolomniveau geen dat abeschikbaar is in de PowerBi REST API, zou een mapping tussen kolommen en queries per rapport manueel moeten aangemaakt en onderhouden worden, met een groot risico op fouten en verouderde mappings. De tweede manier is om te werken met de `SDL Lineage Workflow` van OpenMetadata. Hieraan kan je de `INSERT INTO ... SELECT SQl Queries` meegeven, die een PowerBi rapport voedt. Die queries worden dan automatisch geparseert om de kolomrelaties te ontdekken. Tijdens een bijkomende sync-meeting met de betrokken data-engineers en BI-ontwikkelaars werd bevestigd dat kolomniveau-lineage richting Power BI-rapporten in de huidige VLAIO-context niet op een betrouwbare en onderhoudbare manier kan worden uitgewerkt. OpenMetadata toont wel de queries die in Databricks worden uitgevoerd, maar maakt niet duidelijk welk systeem of rapport een bepaalde query heeft getriggerd, zodat niet eenduidig kan worden afgeleid of een query afkomstig is van Power BI, een Databricks-gebruiker of een intern proces. Daardoor is automatische kolomlineage richting een specifiek Power BI-rapport vandaag niet haalbaar op schaal. De manuele oplossing, via Python-code die de OpenMetadata-API aanstuurt om per rapport kolomlineage in te vullen, werd in de meeting ook beoordeeld als weinig realistisch en een “maintenance hell”.

Om die redenen werd in overleg besloten om kolomniveau-lineage buiten de scope van deze bachelorproef te houden en te focussen op een robuuste lineage op tabelniveau, waarin zichtbaar wordt welke platinum-tabellen de belangrijkste bron vormen voor een rapport. Meer gedetailleerde of manuele verrijking kan in de toekomst eventueel case per case worden toegepast voor een beperkt aantal kritieke rapporten, maar wordt niet als algemene aanpak beschouwd.

### 5.7.4. Scope van de implementatie

Tot slot dekt de huidige end-to-endimplementatie slechts een deel van het VLAIO-rapportagelandschap. De generieke mappinggenerator wordt wel toegepast op de volledige lijst van Power BI-datasets uit de export en levert voor een aanzienlijk deel daarvan betrouwbare `confirmed`-mappings naar platinum-datasets op. In de notebooks en YAML-workflows wordt de flow van mapping naar dashboardcreatie en lineage-opbouw echter alleen volledig uitgevoerd voor een geselecteerde subset van rapporten, met de Steunster/Krissteunster-case als belangrijkste voorbeeld. De resultaten van de gebruikersevaluatie in latere hoofdstukken moeten dan ook gelezen worden als indicaties binnen deze PoC-scope, en niet als bewijs dat het volledige landschap vandaag al end-to-end in OpenMetadata is doorgetrokken.

# 6

# Evaluatie proof-of-concept

## 6.1. Doel en onderzoeksvragen

In dit hoofdstuk wordt de proof-of-concept uit Hoofdstuk 5 geëvalueerd vanuit het perspectief van eindgebruikers en rapportbouwers bij VLAIO. De centrale vraag is in welke mate een expliciet overzicht van dataherkomst en afhankelijkheden, zoals gerealiseerd met OpenMetadata, bijdraagt aan het correct begrijpen en met vertrouwen gebruiken van rapporten.

Meer concreet zijn de onderzoeksvragen als volgt geformuleerd:

- In welke mate ervaren gebruikers vandaag inzicht in de herkomst van cijfers in rapporten, en hoe gaan zij om met wijzigingen of onduidelijkheden in data?
- In welke mate helpt een visueel overzicht van de dataherkomst (lineage) om wijzigingen en hun impact beter te begrijpen?
- Verschilt de ervaren meerwaarde van zo'n overzicht tussen verschillende gebruikersprofielen, zoals rapportgebruikers, rapportbouwers en technische dataprofielen?

Om deze vragen te beantwoorden werd een online vragenlijst afgenomen bij een selectie van rapportgebruikers, rapportbouwers en technische profielen binnen VLAIO. De vragenlijst combineert enerzijds stellingen over de huidige ervaring zonder extra inzicht in dataherkomst, en anderzijds een scenario waarin een concreet herkomstoverzicht getoond wordt op basis van de gerealiseerde proof-of-concept.

## 6.2. Onderzoeksopzet

### 6.2.1. Vragenlijst "Begrijpbaarheid en vertrouwen in rapporten"

De evaluatie maakt gebruik van de vragenlijst *"Begrijpbaarheid en vertrouwen in rapporten"*, opgesteld in Microsoft Forms. De vragenlijst kadert expliciet in deze bachelorproef en licht toe dat de bedoeling is om beter te begrijpen hoe gebruikers rapporten interpreteren en omgaan met wijzigingen of onduidelijkheden in cijfers, en in welke mate extra inzicht in dataherkomst daarbij kan helpen.[1] De bevraging is anoniem, duurt naar schatting vijf tot tien minuten en richt zich op medewerkers die in meer of mindere mate met rapporten (zoals Power BI) werken.

De vragenlijst is thematisch opgebouwd uit vijf blokken:

1. **Profielvragen**: rol (rapportgebruiker, occasionele rapportbouwer, technisch dataprofiel), frequentie van rapportgebruik en zelfgerapporteerde vertrouwdheid met de onderliggende data.
2. **Huidige ervaring zonder extra inzicht**: Likert-schalen (1–5) rond zicht op de herkomst van cijfers, het kunnen verklaren van wijzigingen en het inschatten van impact op andere rapporten, aangevuld met een open vraag naar een concrete situatie waarin men twijfelde aan de cijfers of hun herkomst.
3. **Scenario met herkomstoverzicht**: introductie van een vereenvoudigde visualisatie van de lineageketen (van databronnen en tussenliggende tabellen tot een rapport), gevolgd door stellingen over begrijpelijkheid, bruikbaarheid en impact op vertrouwen, opnieuw op een vijfpuntsschaal.
4. **Extra vragen voor technische profielen**: bijkomende stellingen voor rapportbouwers en technische dataprofielen over de rol van zo'n overzicht bij impactanalyses en het onderbouwen van wijzigingen.
5. **Algemene evaluatie**: algemene stellingen over de meerwaarde en het verwachte gebruik van een herkomstoverzicht, plus een optionele open vraag voor extra opmerkingen of suggesties.

De meeste gesloten vragen maken gebruik van een vijfpuntsschaal van "helemaal oneens" tot "helemaal eens". Dit laat toe om zowel een beschrijvend beeld te schetsen van de huidige situatie als om de ervaren meerwaarde van het herkomstoverzicht kwantitatief te vergelijken. De open vragen bieden ruimte voor nuance en concrete voorbeelden, die gebruikt worden om de kwantitatieve resultaten te duiden en te illustreren.

[1] Zie de volledige formuliertekst in Bijlage **??**.

### 6.2.2. Scenario en visualisatie van dataherkomst

In het derde blok van de vragenlijst wordt de proof-of-concept expliciet in beeld gebracht via een vereenvoudigde visualisatie van de lineageketen. De respondenten krijgen een schematische weergave te zien waarin links de databronnen en tussenliggende datastappen staan, en rechts het rapport dat met deze data gevoed wordt. De verbindingen tonen welke datasets doorstromen naar het rapport, gebaseerd op de in OpenMetadata vastgelegde relaties op tabelniveau.

De introductietekst bij deze visual legt uit dat het overzicht automatisch wordt opgebouwd op basis van metadata, en dat het toelaat om bij een wijziging in één van de datasets na te gaan welke rapporten en cijfers hierdoor geraakt kunnen worden. Op die manier wordt de proof-of-concept vertaald naar een herkenbare gebruikssituatie, waarin respondenten kunnen aangeven in welke mate zo'n overzicht hen zou helpen om wijzigingen en hun impact beter te begrijpen.

## 6.3. Resultaten

### 6.3.1. Profiel van de respondenten

Op het moment van analyse hebben 24 respondenten de vragenlijst volledig ingevuld. Hoewel deze steekproef nog beperkt is, biedt zij een eerste indicatie van de ervaren noden en knelpunten bij het gebruik van rapporten binnen VLAIO.

De verdeling van de respondenten over de verschillende profielen laat zien dat de steekproef hoofdzakelijk bestaat uit personen die rapporten bouwen of inhoudelijk met data werken, aangevuld met een kleinere groep respondenten die rapporten vooral consumeren. Daarnaast geven de meeste respondenten aan wekelijks of dagelijks met rapporten te werken, en zichzelf minstens in zekere mate vertrouwd te achten met de onderliggende data.

Deze samenstelling impliceert dat de resultaten vooral het perspectief weerspiegelen van gebruikers die actief met data en rapporten bezig zijn, eerder dan van volledig niet-technische eindgebruikers. Tegelijk maakt de mix van respondenten het mogelijk om verschillen te signaleren tussen gebruikers die vooral rapporten lezen en respondenten die zelf rapporten opstellen of technisch met data werken.

### 6.3.2. Huidige ervaring zonder expliciet inzicht in dataherkomst

De antwoorden op de stellingen over de huidige situatie suggereren dat respondenten in deze steekproef doorgaans aangeven een redelijk zicht te hebben op waar de cijfers in de rapporten vandaan komen. Tegelijk blijkt dat het begrijpen

van wijzigingen in rapporten en het inschatten van de impact ervan als duidelijk lastiger wordt ervaren.

Meer specifiek geven respondenten vaker aan dat zij meestal kunnen achterhalen waarom cijfers veranderen dan dat zij goed kunnen inschatten welke andere rapporten of onderdelen hierdoor beïnvloed worden. Dit wijst erop dat het zicht op onderlinge afhankelijkheden en de doorwerking van wijzigingen beperkt blijft, ook bij gebruikers die zichzelf relatief vertrouwd achten met de data.

De open antwoorden bevestigen dit beeld en geven concreet kleur aan deze bevinding. Respondenten geven onder meer aan dat onzekerheid vaak ontstaat wanneer de betekenis van cijfers niet volledig duidelijk is, of wanneer rapporten door andere teams zijn opgebouwd. Daarbij wordt verwezen naar onduidelijkheid over definities, het effect van filters, de interpretatie van geaggregeerde waarden en het onderscheid tussen fouten in data en fouten in de rapportopbouw zelf.

Een eerste terugkerend patroon is dat gebruikers niet altijd zeker weten wat een cijfer precies vertegenwoordigt. Zo beschrijven respondenten situaties waarin niet duidelijk is of een waarde betrekking heeft op toegekende of finaal uitbetaalde steun, of waarin een wijziging in een rapport zichtbaar is zonder dat meteen duidelijk is of die verandering voortkomt uit de brondata, uit een aangepaste definitie of uit een fout in het rapport. Ook gevallen waarin dezelfde data in verschillende rapporten anders worden geïnterpreteerd, komen terug in de antwoorden.

Daarnaast blijkt uit de open antwoorden dat zelfs respondenten met een hoger technisch profiel niet altijd volledige zekerheid hebben over de herkomst en betekenis van data. Meerdere respondenten geven aan dat het lang duurt voor een dataset door en door gekend is, en dat zelfs na jaren werken met een dataset nog onverwachte effecten kunnen opduiken na een wijziging.[2] Dit bevestigt dat de complexiteit van datastromen niet uitsluitend een probleem is voor niet-technische gebruikers, maar ook voor personen die dichter bij de data staan.

Deze bevindingen suggereren dat, zonder expliciet inzicht in dataherkomst en afhankelijkheden, gebruikers moeite blijven hebben om wijzigingen correct te interpreteren en de impact ervan breed in te schatten.

[2] Bijvoorbeeld: “het duurt heel lang voor je een dataset door en door kent. Zelfs na jaren ermee te werken kan er plots iets opduiken wat je niet had verwacht na een change”.

### 6.3.3. Ervaren meerwaarde van het lineage-overzicht

Na het tonen van de lineage-visualisatie geeft een groot deel van de respondenten aan dat dit overzicht hen helpt om sneller te zien waar cijfers vandaan komen en om beter te begrijpen waarom cijfers veranderen. Ook het inschatten van welke onderdelen of rapporten beïnvloed worden door wijzigingen in data wordt door veel respondenten als duidelijker ervaren.

Dit wijst erop dat het visualiseren van dataherkomst en afhankelijkheden, zelfs in een vereenvoudigde vorm op tabelniveau, voor deze steekproef een directe meerwaarde biedt als ondersteuning bij impactanalyse op rapportniveau. De proof-of-concept lijkt er dus in te slagen om een aantal eerder geïdentificeerde knelpunten gedeeltelijk te adresseren, in het bijzonder het ontbreken van een centraal overzicht van betrokken datasets en rapporten.

Tegelijkertijd maken zowel de Likert-scores als de open antwoorden duidelijk dat deze meerwaarde niet volledig is. Meerdere respondenten geven aan dat het getoonde overzicht te generiek blijft en onvoldoende detail bevat om te begrijpen hoe specifieke waarden precies zijn opgebouwd. Er wordt onder meer gewezen op het ontbreken van informatie over transformaties, businesslogica, de betekenis van velden en de precieze inhoud van tabellen of subcomponenten.[3]

De antwoorden tonen bovendien dat gebruikers behoefte hebben aan aanvullende context bovenop de visualisatie zelf. Zo vragen verschillende respondenten expliciet naar informatie over welke kolommen of velden exact gebruikt worden, hoe een waarde binnen een bron is opgebouwd, welke verwerking plaatsvindt tussen bron en rapport en hoe snel gegevens actueel zijn. Een aantal respondenten merkt ook op dat het huidige overzicht vooral een statische momentopname is, terwijl inzicht in timing, verwerking en wijzigingsgeschiedenis nuttig zou zijn om de impact van veranderingen beter te begrijpen.[

Ook technisch onderlegde respondenten geven aan dat, hoewel het overzicht een eerste inzicht biedt in de structuur van de datastromen, het niet volstaat om complexe wijzigingen volledig te analyseren. De lineage-visualisatie uit de PoC wordt daardoor eerder gezien als een oriënterend hulpmiddel dan als een volledig verklarend instrument.

[3] Bijvoorbeeld: “je hebt nu enkel bronnen, maar je weet niet hoe data binnen een bepaalde bron is opgebouwd” en “dit geeft de lineage weer, hetgeen zeker een eerste zicht geeft over de data en databronnen. Maar dat geeft nog niet weer hoe zo’n model opgebouwd is.”

### 6.3.4. Impact op vertrouwen en gebruik

Wat betreft vertrouwen en gebruik geeft een meerderheid van de respondenten aan dat een dergelijk overzicht een positieve invloed kan hebben op het vertrouwen in rapporten. Daarnaast geven veel respondenten aan dat zij een dergelijke functionaliteit effectief zouden gebruiken indien deze beschikbaar is in hun werkomgeving, en dat zij het nuttig zouden vinden als rapporten standaard een link naar zo'n overzicht bevatten.
Dit suggereert dat er binnen deze steekproef een duidelijke behoefte bestaat aan meer transparantie in dataherkomst en afhankelijkheden, en dat lineage-overzichten daarin een belangrijke rol kunnen spelen.

Tegelijk tonen de resultaten aan dat het verhogen van vertrouwen niet uitsluitend afhankelijk is van het zichtbaar maken van herkomst. Het ontbreken van detail en context in het huidige overzicht vormt een belangrijke beperking voor het volledig begrijpen van cijfers en hun evolutie. Verschillende respondenten geven expliciet aan dat het vertrouwen pas echt toeneemt wanneer zij niet alleen zien *waar* data vandaan komt, maar ook *wat* er precies veranderd is, *hoe* gegevens verwerkt werden en *waarom* bepaalde conclusies in een rapport tot stand komen.

Een aantal antwoorden benadrukt bovendien dat extra businessmetadata een belangrijke aanvulling zou zijn. Respondenten vragen om duidelijke definities van begrippen en indicatoren, om de koppeling tussen technische velden en businesstermen, en om een vlottere manier om van een bron- of veldnaam naar de betekenis ervan te navigeren. Dit wijst erop dat lineage op zichzelf wel bijdraagt aan transparantie, maar dat vertrouwen pas volledig ondersteund wordt wanneer technische herkomst gecombineerd wordt met semantische uitleg.

### 6.3.5. Verschillen tussen gebruikersprofielen

Hoewel de steekproef niet groot genoeg is om statistisch robuuste vergelijkingen te maken, wijzen de antwoorden wel op enkele inhoudelijke verschillen tussen gebruikersprofielen.

Respondenten die zelf rapporten bouwen of technisch met data werken, geven vaker aan dat zij reeds een zekere basiskennis hebben van de datastromen, maar benadrukken tegelijk dat zij niet altijd inzicht hebben in de volledige keten of in de logica achter data van andere teams. Voor hen is het overzicht vooral nuttig als eerste oriëntatie en als ondersteuning bij het opsporen van afhankelijkheden over team- of domeingrenzen heen.

Rapportconsumenten focussen in hun antwoorden vaker op begrijpbaarheid en

vertrouwen. Zij geven aan dat het visuele overzicht helpt om sneller te begrijpen waar cijfers vandaan komen, maar ook dat het moeilijk blijft om abstracte schema's correct te interpreteren zonder extra toelichting. Voor deze groep is vooral de vraag relevant of een waarde nog betrouwbaar en interpreteerbaar is wanneer er iets verandert in de onderliggende data.

De resultaten suggereren bijgevolg dat de ervaren meerwaarde van lineage varieert naargelang het profiel van de gebruiker. Voor technische profielen ondersteunt lineage in de eerste plaats het identificeren van betrokken datasets en rapporten en het structureren van impactanalyses, terwijl niet-technische gebruikers er vooral baat bij hebben om de herkomst van cijfers en de betekenis van wijzigingen beter te begrijpen.

### 6.3.6. Synthese en kritische interpretatie

Samenvattend tonen de resultaten dat het lineage-overzicht in de context van deze proof-of-concept een zinvolle toevoeging is als eerste stap in het ondersteunen van impactanalyse. De PoC biedt respondenten een centraal, visueel zicht op herkomst en afhankelijkheden, waardoor zij sneller kunnen inschatten welke rapporten en datasets mogelijk betrokken zijn bij een wijziging. Daarmee wordt een belangrijk pijnpunt in het huidige proces aangepakt, namelijk het ontbreken van een centrale en doorzoekbare basis voor het identificeren van impact.

Tegelijk blijkt dat een overzicht op tabelniveau onvoldoende is om de volledige impact van wijzigingen te begrijpen of om het vertrouwen in alle gevallen substantieel te verhogen. Respondenten vragen expliciet om meer detail, bijkomende businesscontext en zicht op transformaties, definities en de opbouw van specifieke waarden. Dit wijst erop dat lineage vooral waardevol is als basislaag voor transparantie en oriëntatie, maar dat bijkomende metadata nodig zijn om impactanalyse ook inhoudelijk en interpretatief te ondersteunen.

De resultaten bevestigen dus dat de gerealiseerde proof-of-concept een relevante eerste stap vormt in de richting van beter ondersteunde impactanalyses bij VLAIO. De meerwaarde zit daarbij vooral in het zichtbaar maken van afhankelijkheden en het verhogen van de transparantie, terwijl de geformuleerde beperkingen duidelijk aangeven waar verdere uitbreidingen — zoals fijnmazigere lineage (bijvoorbeeld op kolomniveau) of aanvullende businessmetadata — mogelijk nodig zijn om de volledige potentie voor begrijpbaarheid en vertrouwen te realiseren.

# 7

# Conclusie

TODO

# A

# Onderzoeksvoorstel

Het onderwerp van deze bachelorproef is gebaseerd op een onderzoeksvoorstel dat vooraf werd beoordeeld door de promotor. Dat voorstel is opgenomen in deze bijlage.

## Samenvatting

In complexe data-omgevingen als VLAIO worden er zeer grote hoeveelheden aan data verwerkt, uit diverse bronnen en pipelines. Dit zorgt ervoor dat het voor data engineers en stakeholders niet altijd duidelijk is waar deze data vandaan komt en welke transformaties eraan voorafgingen. Dit zorgt voor trage impactanalyses en een verhoogd risico op fouten in rapportage. Er is dus nood aan een betrouwbaar lineage-systeem dat de herleidbaarheid van impactanalyses overzichtelijk maakt. Om deze behoefte aan een betrouwbaar lineage-systeem te onderzoeken wordt er een case study uitgevoerd met metingen voor en na het invoeren van een proof-of-concept in OpenMetadata. Een aantal impactanalyse-rapporten zullen geëvalueerd worden op meetbare criteria als traceerbaarheid van de berekeningsstappen, tijdsduur van wijzigingsanalyses en duidelijkheid van de rapportages voor de stakeholders. Tijdens deze metingen worden er bron- en schemawijzigingen gesimuleerd om de effecten op de herleidbaarheid systematisch te meten. De verwachte resultaten zijn een aantoonbare verbetering in de transparantie van de dataflows, een hogere mate van traceerbaarheid van berekeningen en een verhoogde duidelijkheid van de rapportage. Als deze verwachte resultaten bevestigd worden, betekent dit dat OpenMetadata een geschikte tool is om de impactanalyse bij VLAIO beter herleidbaar en transparanter te maken, met dus als gevolg een meer betrouwbare datagedreven besluitvorming. De centrale onderzoeksvraag van deze bachelorproef luidt:

**“In welke mate verhogen lineage-functionaliteit en API-integraties**

**van OpenMetadata de transparantie en herleidbaarheid van impact-analyses bij VLAIO?**

## A.1. Inleiding

### A.1.1. Onderzoeksopzet

In moderne bedrijven met complexe data omgevingen is een inzicht in data lineage, ofwel de volledige weg van bron tot rapport, inclusief alle transformaties en afhankelijkheden, cruciaal. Data lineage zorgt voor compliance, kwaliteitsbewaking en impactanalyse. Daarnaast zorgt het er ook voor dat organisaties snel kunnen reageren wanneer er data-fouten optreden. Echter is het integreren van een effectieve lineage-oplossing met bestaande databronnen en pipelines uitdagend.

### A.1.2. Probleemstelling

Bij VLAIO wordt er gewerkt met grote hoeveelheden data voor hun impactanalyses, die uit vele bronnen en pipelines komen. Op dit moment is er nog een duidelijk gebrek aan een transparant lineage-systeem, waardoor data-engineers en business analisten niet altijd precies kunnen achterhalen waar gebruikte gegevens juist vandaan komen en welke transformaties deze hebben ondergaan. Dit zorgt voor vertraagde impactanalyses, een groter risco op fouten in rapportages en een verminderd vertrouwen in data-gedreven besluitvorming.

### A.1.3. Onderzoeksvraag

Vanwege het belang van transparantie en herleidbaarheid in data-gedreven organisaties en de huidige tekortkomingen bij VLAIO rijst de centrale onderzoeksvraag:

**“In welke mate verhogen lineage-functionaliteit en API-integraties van OpenMetadata de transparantie en herleidbaarheid van impact-analyses bij VLAIO?**

Om deze vraag goed te kunnen beantwoorden wordt het onderzoek opgesplits in deelvragen:

**Deelvragen probleemdomein:**

1. Wat is data lineage, welke rol speelt het in data governance en compliance, en welke risico’s ontstaan wanneer lineage ontbreekt in complexe data-omgevingen?
2. In welke mate zijn de impactanalyse-rapporten bij VLAIO momenteel transparant en herleidbaar, en hoeveel tijd en moeite kost het om wijzigingen of fouten te analyseren?

**Deelvragen oplossingsdomein:**

3. Wat zijn de kernfunctionaliteiten van data catalog en metadata management tools zoals OpenMetadata voor het beheren van data lineage via API-integraties en connectors?
4. Hoe volledig en nauwkeurig kan de lineage in OpenMetadata worden weergegeven voor representatieve impactanalyses bij VLAIO?
5. In welke mate verbetert OpenMetadata de analysetijd, traceerbaarheid en duidelijkheid van impactanalyse-rapporten voor verschillende stakeholders bij VLAIO?
6. Welke praktische barrières en aanbevelingen komen naar voren voor eventuele verdere implementatie van OpenMetadata binnen VLAIO?

Vraag één en drie zullen via de literatuurstudie worden beantwoord. De andere deelvragen zullen empirisch worden onderzocht via een case study bij VLAIO.

### A.1.4. Onderzoeksdoelstelling

Het doel van dit onderzoek is een kwalitatief en kwantitatief onderbouwde evaluatie, die aantoont in welke mate OpenMetadata de transparantie en herleidbaarheid van de impactanalyses bij VLAIO verbetert. Dit wordt getest met een case-study, waarbij voor- en nametingen vergeleken worden. Representatieve impactanalyse-rapporten zullen eerst geanalyseerd worden op meetbare criteria als traceerbaarheid, herleidbaarheid en duidelijkheid. Deze kunnen gemeten worden aan de hand van bijvoorbeeld een scorelijst met een score van 1–5 of met kwantitatieve metrics als het aantal stappen/kliks voor tracing en een percentage van fouten. De definitieve methode wordt gekozen op basis van pilot-tests." De criteria kunnen gemeten worden aan de hand van een scorelijst (1–5-schaal met ankers per criterium) of kwantitatieve metrics zoals het aantal stappen/kliks voor tracing en percentage foutieve herleidingen. De definitieve methode wordt na overleg met de copromotor bij VLAIO gekozen. Vervolgens wordt een proof-of-concept opgezet met OpenMetadata en zullen dezelfde criteria opnieuw gemeten en vergeleken worden. De doelgroep bestaat uit data-engineers en andere stakeholders bij VLAIO die kunnen bepalen op basis van dit onderzoek hoe ze lineage structureel in hun impactanalyses kunnen integreren en of dit de moeite is. Dit onderzoek geeft een evaluatie van de effecten van een lineage systeem met OpenMetadata door objectieve meetresultaten.

## A.2. Literatuurstudie

### A.2.1. De rol van data lineage in data governance

Data lineage verwijst naar de volledige weg die data in een organisatie aflegt van bron tot eindrapport (VLAIO, 2025). Het beschrijft zowel de herkomst van de data, als alle transformaties die de data ondergaat en de afhankelijkheden ervan.

Zoals Verma et al. (2024) beschreven, beweegt data met verschillende stappen door een data pipeline, waarbij deze continu van structuur verandert. Data lineage bevat alle informatie omtrent deze stroom van data en toont hoe data wordt verzameld, verwerkt en uiteindelijk gebruikt binnen de organisatie. Het omvat zaken zoals het volgen van bestemmingen van gegevens, validatiestappen, kwaliteitscontroles, impactanalyses en vergemakkelijkt het opsporen van fouten en problemen.
Naast data lineage wordt er in veel literatuur ook gesproken over provenance (Secoda, 2024). Data lineage is in feite het praktische aspect van provenance. Terwijl data lineage gaat over de route van data door verschillende systemen en processen, is provenance de hele geschiedenis en context die de data beschrijft. Een gebrek aan deze lineage of provenance zorgt ervoor dat het niet altijd duidelijk is wat nu tot een bepaald resultaat heeft geleid. Hierdoor ontstaat een verminderde controleerbaarheid van rapportages en impactanalyses, en een verhoogd risico op fouten in besluitvorming (Verma et al., 2024).

### A.2.2. Compliance en transparantie

Naast praktische voordelen zoals traceerbaarheid en foutopsporing is data lineage ook van belang in regelgevingscontexten als GDPR en andere compliancevereisten (Collibra, 2025). Hoewel het niet altijd wettelijk verplicht is voor een organisatie om een volledig lineage systeem te hebben, is het essentieel om te kunnen aantonen waar gegevens vandaan komen, naar toe gaan en hoe ze verwerkt worden. Governance en lineage maken dit transparant en controleerbaar, wat zorgt voor betrouwbare rapportages en impactanalyses. Het ontbreken ervan daarentegen kan leiden tot compliance-risico's, hogere auditkosten en een verminderd vertrouwen van de stakeholders in de data (Dataversity, 2025).

### A.2.3. Impactanalyses

Impactanalyses tonen aan welke gevolgen een wijziging of maatregel heeft op processen, systemen of personen binnen de organisatie en vereisen betrouwbare en reproduceerbare data (Verma et al., 2024). Volledige data lineage is dus cruciaal voor het maken van goede impactanalyses. Een ontbrekende of onvolledige lineage kan het risico op foutieve conclusies verhogen en maakt daarnaast ook het analyseren van wijzigingen een traag proces (Bernardo et al., 2024). Met lineage kan je zien hoe elke waarde in een rapport is ontstaan en waar deze vandaan komt, wat zorgt voor traceerbaarheid, reproduceerbaarheid en betrouwbaarheid (Wittner et al., z.d.). Data lineage draagt zo dus direct bij aan de transparantie en herleidbaarheid van impactanalyses, met als gevolg een hogere geloofwaardigheid van de resultaten voor stakeholders.

### A.2.4. OpenMetadata als governance tool

OpenMetadata is een open-source tool die kan gebruikt worden voor data-catalogusbeheer en metadata management binnen een data-governance omgeving (OpenMetadata, 2024d). Het biedt functionaliteiten voor het automatisch ontdekken van databronnen, table- en column-level lineage tracking en het monitoren van data kwaliteit. Daarnaast geeft het ook de mogelijkheid om met API-integraties OpenMetadata te koppelen aan vele andere systemen als PowerBI, Kafka, Snowflake, Databricks, enzovoort. Hierdoor kan je een volledig overzicht van de hele dataketen opbouwen.

### A.2.5. Praktijkervaringen met OpenMetadata

Meerdere organisaties hebben OpenMetadata reeds succesvol geïmplementeerd voor data governance. Bij Carrefour Brazil bijvoorbeeld leidde de implementatie tot een lineage-systeem met datakwaliteits-monitoring, automatische tracking voor kritieke dataflows en zorgde dat meer dan 500 gebruikers betrouwbaar de juiste bronnen kunnen vinden (OpenMetadata, 2024a). Ook (OpenMetadata, 2024c) beschrijft hoe inDrive OpenMetadata succesvol inzet met meer dan 100 AWS-databases, voor compliance automation en een data-governance systeem op globale schaal. Nog een relevante case is van FREENOW, waar het werd ingezet voor het beheren van ongeveer 17.000 data-assets en meer dan 300 downstream dependencies aan de hand van API-integraties (OpenMetadata, 2024b). Deze voorbeelden uit de praktijk tonen aan dat OpenMetadata geschikt is voor complexe data-omgevingen met uitgebreide integratie-vereisten, vergelijkbaar met de situatie bij VLAIO. Community discussies op r/dataengineering en r/bigdata bevestigen positieve ervaringen met deployment en extensibiliteit van OpenMetadata (Reddit r/dataengineering, r/bigdata, 2025).

### A.2.6. Best practices

Uit meerdere literatuur- en casestudies komen verschillende succesfactoren naar voren bij het implementeren van data lineage. (Bernardo et al., 2024) benadrukt in een systematische review over data-governance dat organisaties de beste resultaten behalen, wanneer ze de implementatie in fases aanpakken. Door te starten met een kleiner aantal kritieke dataflows, geraken ze vertrouwd met het systeem, waardoor ze daarna kunnen uitbreiden naar de rest van het datalandschap. Dit zou volgens hen beter werken dan een big-bangimplementatie, die complex en risicovol is.

Daarnaast zijn managementondersteuning en duidelijke verantwoordelijkheden van belang bij het succesvol integreren van lineage/governance projecten (Dataversity, 2025). Een veelvoorkomende uitdaging is de complexiteit van de bestaande data-omgevingen, verzet tegen veranderingen van medewerkers en technische beperkingen zoals automatisch detecteren van lineage bij legacy-systemen (Se-

coda, 2024). De best practise is om te starten met goed gedocumenteerde, moderne systemen en stapsgewijs uit te breiden.

### A.2.7. Onderzoeksleemte

Er bestaat reeds literatuur over data governance en uitgebreide documentatie over de functionaliteiten die tools als OpenMetadata bieden. Wat er echter nog mist is kwantitatief onderzoek dat de impact van lineage-implementaties op operationele processen als impactanalyses, systematisch meet. De huidige studies zijn voornamelijk kwalitatief en gaan niet in op voor- en nametingen van specifieke indicatoren, als traceerbaarheid en ervaring van stakeholders. Dit onderzoek onderscheidt zich door de impact van OpenMetadata op impactanalyses bij VLAIO te evalueren. Op deze manier wordt het duidelijk of het implementeren van een lineage-syteem met OpenMetadata daadwerkelijk bijdraagt aan de transparantie, herleidbaarheid en efficiëntie van impactanalyses in de praktijk.

## A.3. Methodologie

### A.3.1. Voorbereidende fase: Literatuurstudie

Voordat de case study start, wordt een literatuurstudie uitgevoerd om deelvraag 1 te beantwoorden. Dit omvat:

- Analyse van data lineage concepten en best practices (Verma2024, bernardo2024data)
- Vergelijking van OpenMetadata met alternatieven (OpenMetadataDocs2024)
- Review relevante metrics voor data governance evaluatie

**Deliverable**: Afgewerkte literatuurstudie.

### A.3.2. Fase 1: Analyse huidige situatie en nulmeting (3 weken)

Dit onderzoek zal een toegepaste case study zijn met een voor en nameting om de impact van OpenMetadata op de transparantie en herleidbaarheid van impactanalyses bij VLAIO te evalueren. De methodologie is opgedeeld in vier fasen, waarbij elke fase concrete, meetbare resultaten oplevert.
In deze fase wordt de huidige situatie bij VLAIO geanalyseerd om de tweede deelvraag van het probleemdomein te beantwoorden. In overleg met de co-promotor worden representatieve impactanalyse-rapporten gekozen die regelmatig worden opgesteld en verschillende databronnen en transformaties omvatten. Voor deze rapporten worden volgende indicatoren gemeten:

**Traceerbaarheid** Hoeveel stappen in de dataflow (van bron tot rapport) kunnen momenteel expliciet worden geïdentificeerd en gedocumenteerd? Dit wordt gemeten door per rapport te inventariseren welke bronnen, transformaties en

tussenresultaten beschreven zijn in de huidige documentatie. Een voorbeeld hiervan is: ETL → Data Warehouse → Power BI (3 traceerbare stappen).

**Analysetijd** Hoeveel tijd kost het om de impact van een schemawijziging of datafout te analyseren? Dit wordt gemeten door een gecontroleerde oefening uit te voeren waarbij een fictieve wijziging wordt gesimuleerd en de tijd met een timer wordt bijgehouden die nodig is om alle geraakte downstream-componenten te identificeren. Deze oefening kan toegepast worden op meerdere data-engineers bij VLAIO waarbij dan de gemiddelde tijd wordt genomen.

**Duidelijkheid** Hoe begrijpelijk zijn de huidige rapporten en documentatie over dataherkomst voor verschillende stakeholders? Dit kan kwalitatief geëvalueerd worden via korte surveys met 3–5 stakeholders (data engineers en business analisten).

Tijdens deze fase worden ook de bestaande data-architecturen gedocumenteerd: welke databronnen (bijvoorbeeld databases, data warehouses, ETL/ELT-tools), pipelines (bijvoorbeeld Apache Airflow, dbt) en rapportage-tools (bijvoorbeeld Power BI) zijn relevant voor de geselecteerde impactanalyses?
**Deliverables:**

- Inventarisatiedocument met geselecteerde impactanalyse-rapporten en beschrijving van de huidige data-architectuur
- Nulmeting-rapport met kwantitatieve metrics (aantal traceerbare stappen, analysetijd) en kwalitatieve inzichten (knelpunten, onduidelijkheden)

### A.3.3. Fase 2: Ontwerp en implementatie proof-of-concept (4 weken)

In deze fase wordt er een proof-of-concept met OpenMetadata ontworpen en geïmplementeerd. De PoC richt zich op de geselecteerde impactanalyse-rapporten en omvat:

**Installatie en configuratie** OpenMetadata wordt geïnstalleerd in een testomgeving bij VLAIO. De basisinstellingen worden geconfigureerd, waaronder gebruikersbeheer, toegangsrechten en organisatiestructuur, ...

**Connectoren en integraties** Via de beschikbare connectors en API's van OpenMetadata worden de relevante databronnen, pipelines en BI-tools aangesloten. Dit omvat bijvoorbeeld volgende zaken:

- Databronnen (bijv. PostgreSQL, Snowflake, Databricks)
- ETL/ELT-tools (bijv. Apache Airflow, dbt)
- Rapportage-tools (bijv. Power BI, Tableau)

**Lineage-configuratie** Table-level en waar mogelijk column-level lineage wordt geconfigureerd voor de dataflows die invloed hebben op de geselecteerde impactanalyserapporten. Hierbij wordt gebruikgemaakt van automatische lineage-detectie waar beschikbaar, en handmatige aanvulling waar nodig.

**Metadata-verrijking** Relevante metadata wordt toegevoegd om de context en betekenis van datasets en transformaties te verduidelijken.

**Documentatie** Alle stappen, configuraties en eventuele aanpassingen worden gedocumenteerd om reproduceerbaarheid te waarborgen en als basis te dienen voor toekomstig vervolg.

Tijdens deze fase worden ook eventuele technische uitdagingen of beperkingen geïdentificeerd en gedocumenteerd.
**Deliverables:**

- Werkende proof-of-concept van OpenMetadata met geconfigureerde lineage voor de geselecteerde impactanalyses
- Technische documentatie en installatiehandleiding
- Logboek met geïdentificeerde uitdagingen en oplossingen

### A.3.4. Fase 3: Nameting en evaluatie (2 weken)

Na de implementatie van de PoC wordt een nameting uitgevoerd met dezelfde indicatoren als in fase 1, om de impact van OpenMetadata te kunnen meten. Daarnaast kunnen in deze fase ook praktische barrières en succesfactoren geïdentificeerd worden via surveys/interviews met betrokkenen. Bijvoorbeeld: Wat viel op tijdens het gebruik van OpenMetadata? Welke functionaliteiten zijn het meest waardevol? Waar liggen beperkingen of verbeterpunten?
**Deliverables:**

- Nameting-rapport met kwantitatieve metrics en vergelijking met de nulmeting
- Kwalitatieve analyse van stakeholder-ervaringen en geïdentificeerde barrières
- Aanbevelingen voor verdere implementatie en uitrol

### A.3.5. Fase 4: Analyse, rapportage en aanbevelingen (3 weken)

In de laatste fase worden alle verzamelde gegevens geanalyseerd en wordt de bachelorproef uitgeschreven. De kwantitatieve resultaten (traceerbaarheid, analysetijd) worden statistisch vergeleken tussen de voor- en nameting om vast te stellen of er significante verbeteringen zijn. De kwalitatieve inzichten uit interviews en observaties worden thematisch geanalyseerd om patronen, succesfactoren en uitdagingen te identificeren.

**Deliverables:**

- Volledige bachelorproefscriptie met resultaten, analyse, conclusies en aanbevelingen

### A.3.6. Tools en technologieën

- OpenMetadata: Open-source data catalog en metadata management platform
- Databronnen en pipelines bij VLAIO: Afhankelijk van de bestaande infrastructuur (bijv. PostgreSQL, Snowflake, Databricks, Apache Airflow, dbt, Power BI)
- Documentatietools: Microsoft Word/LaTeX voor documentatie en rapportage
- Tijdmeting: Eenvoudige tijdregistratievoor het meten van analysetijden
- Survey: Likert-schaal (1–5) voor kwalitatieve beoordeling van duidelijkheid

## A.4. Verwacht resultaat, conclusie

Op basis van de literatuur en de geplande case-study bij VLAIO worden de volgende resultaten verwacht:

- **Verbeterde traceerbaarheid:** Na implementatie van OpenMetadata wordt verwacht dat een groter aantal stappen in de dataflow van bron tot rapport expliciet zichtbaar en gedocumenteerd is. Dit zal kwantitatief gemeten worden door het aantal traceerbare bronnen, transformaties en tussenresultaten per impactanalyse-rapport te tellen.
- **Verminderde analysetijd:** Door gebruik van lineage-visualisaties in OpenMetadata wordt verwacht dat de tijd om de impact van wijzigingen of fouten te analyseren afneemt. Deze tijd wordt kwantitatief gemeten door gecontroleerde simulaties van fictieve wijzigingen, waarbij de benodigde tijd voor identificatie van downstream-componenten wordt geregistreerd.
- **Verbeterde duidelijkheid van rapporten:** Het gebruik van OpenMetadata maakt de structuur en herkomst van data inzichtelijker voor stakeholders. Dit wordt kwalitatief geëvalueerd met een scorecard (Likert-schaal 1–5) voor begrijpelijkheid en bruikbaarheid van de rapporten en lineage-visualisaties.
- **Identificatie van praktische barrières en succesfactoren:** Het onderzoek zal inzicht geven in welke functionaliteiten van OpenMetadata het meest waardevol zijn en welke beperkingen of uitdagingen er bestaan bij de implementatie in een complexe data-omgeving zoals bij VLAIO.

## Verwachte conclusies

Op basis van de metingen en evaluaties wordt verwacht dat OpenMetadata concreet bijdraagt aan:

- Hogere transparantie en herleidbaarheid van impactanalyses
- Betere reproduceerbaarheid en betrouwbaarheid van rapportages
- Efficiëntere processen bij analyse van wijzigingen en fouten
- Praktische aanbevelingen voor verdere implementatie binnen VLAIO

## Meerwaarde voor de doelgroep

De resultaten van dit onderzoek bieden VLAIO een objectief en kwantitatief onderbouwd inzicht in de effecten van een lineage-tool. Data engineers en business analisten krijgen een beter overzicht van de volledige dataflow en kunnen sneller en betrouwbaarder impactanalyses uitvoeren. Bovendien levert het onderzoek concrete aanbevelingen op voor het structureel integreren van OpenMetadata binnen de organisatie, waardoor toekomstige projecten tijds- en foutreductie realiseren.

# Bibliografie


Bernardo, B. M. V., São Mamede, H., Barroso, J. M. P., & Dos Santos, V. M. P. D. (2024). Data governance & quality management—Innovation and breakthroughs across different fields. *Journal of Innovation & Knowledge*, *9*(4), 100598.

Collibra. (2025). *Five reasons why data lineage is essential for regulatory compliance*. Geraadpleegd op 12 december 2025, van https://www.collibra.com/blog/five-reasons-why-data-lineage-is-essential-for-regulatory-compliance

Dataversity. (2025). *Harnessing Data Lineage to Enhance Data Governance Frameworks*. Geraadpleegd op 12 december 2025, van https://www.dataversity.net/articles/harnessing-data-lineage-to-enhance-data-governance-frameworks/

Eichler, R., Giebler, C., Gröger, C., Hoos, E., Schwarz, H., & Mitschang, B. (2021). Enterprise-wide metadata management: an industry case on the current state and challenges. *Business Information Systems*, 269–279.

infobelPRO. (2025, 1 oktober). *Data provenance vs data lineage: Wat is het verschil?* Geraadpleegd op 1 oktober 2025, van https://www.infobelpro.com/en/blog/data-provenance-vs-data-lineage

Kretsou, M., Arvanitou, E.-M., Ampatzoglou, A., Deligiannis, I., & Gerogiannis, V. C. (2021). Change impact analysis: A systematic mapping study. *Journal of systems and software*, *174*, 110892.

Malviya, S., Jaiswal, A., & Koli, V. (2025). A DBT-Based Column Lineage Tracking Approach for Regulatory and Audit Compliance. *J. Electrical Systems*, *21*(01), 1022–1033.

Mayernik, M. S., DiLauro, T., Duerr, R., Metsger, E., Thessen, A. E., & Choudhury, G. S. (2013). Data conservancy provenance, context, and lineage services: Key components for data preservation and curation. *Data Science Journal*, *12*, 158–171.

OpenMetadata. (2024a). *Carrefour Brazil: Data Governance Success with OpenMetadata*. Geraadpleegd op 12 december 2025, van https://open-metadata.org/case-study/carrefour-brazil

OpenMetadata. (2024b). *FREENOW: OpenMetadata powered Data Announcement System*. Geraadpleegd op 12 december 2025, van https://open-metadata.org/case-study/freenow

OpenMetadata. (2024c). *inDrive Scales Global Data Governance with OpenMetadata*. Geraadpleegd op 12 december 2025, van https://open-metadata.org/case-study/indrive

OpenMetadata. (2024d). *OpenMetadata Documentation*. Geraadpleegd op 12 december 2025, van https://docs.open-metadata.org/

Patel, S., Rahevar, M., & Parmar, M. (2020). Data provenance and data lineage in the cloud: a survey. *International Journal of Advanced Science and Technology*, *29*(5), 4883–4900.

Reddit r/dataengineering, r/bigdata. (2025). Community experiences with OpenMetadata [Multiple threads discuss successful deployments and community support]. https://www.reddit.com/r/dataengineering/search?q=OpenMetadata

Secoda. (2024). *How does data lineage fit into the framework of data governance?* Geraadpleegd op 12 december 2025, van https://www.secoda.co/blog/data-lineage-in-data-governance

Tang, D., Zhao, R., Lin, Y., Zhang, T., & Zhang, P. (2022). Modeling the data provenance of relational databases supporting full-featured SQL and procedural languages. *Applied Sciences*, *13*(1), 64.

Verma, R., Shrivastava, P., & Merla, N. (2024). Tracing the path: Data lineage and its impact on data governance. *International Journal of Global Innovations and Solutions (IJGIS)*.

VLAIO. (2025). *Intern bestand* (Intern document, niet publiek beschikbaar). Vlaams Agentschap Innoveren & Ondernemen.

Wittner, R., Mascia, C., Gallo, M., Frexia, F., et al. (z.d.). Lightweight Distributed Provenance Model for Complex Real–world Environments. Scientific Data 2022; 9: 503.